



UNIVERSIDAD
DE MÁLAGA



UNIVERSIDAD DE MÁLAGA
Escuela de Ingenierías Industriales
Departamento de Lenguajes y Ciencias de la Computación

Trabajo Fin de Grado

Grado en Ingeniería Mecánica

EDA y predicción de tendencias en el consumo y la sostenibilidad energética mundial utilizando aprendizaje automático

Realizado por:

Juan Jesús Gómez Ortiz

Tutorizado por:

M^a Carmen Aranda Garrido

Málaga, junio de 2026

Resumen

El presente Trabajo de Fin de Grado aborda el análisis exploratorio de datos y la predicción mediante técnicas de aprendizaje automático del consumo energético global y las emisiones de dióxido de carbono, utilizando un panel de datos de 176 países durante el periodo 2000–2020. El estudio se enmarca en la intersección entre la ingeniería mecánica, la ciencia de datos y la política energética, con el objetivo de aportar una visión cuantitativa a los desafíos de la transición energética.

Se emplean dos conjuntos de datos principales: el *Global Data on Sustainable Energy* (Kaggle, 2000–2020) como fuente primaria, y el dataset de *Our World in Data* (OWID) como referencia para validación externa. La metodología comprende una fase de análisis exploratorio exhaustivo (distribuciones univariadas, detección de outliers, correlaciones, análisis de multicolinealidad mediante VIF y análisis temporal) seguida de una fase de modelado predictivo con dos modelos diferenciados.

Por un lado, el Modelo A predice las emisiones de CO₂ por país empleando regresión lineal, Ridge y Random Forest, consiguiendo un R² de 0,91 con la versión Ridge tras excluir la generación fósil para evitar predicción cuasi-tautológica. Por otro lado, el Modelo B predice el consumo energético per cápita, donde el Random Forest logra un R² de 0,963, capturando relaciones no lineales que los modelos lineales no detectan.

Adicionalmente, se realiza un análisis de compatibilidad entre ambos datasets, revelando incompatibilidades sistemáticas de escala que hace inviable compararlos directamente para este trabajo, pero resultando esto en sí mismo en otro hallazgo metodológico relevante.

Se incluye además una contextualización socioeconómica del panorama energético global, el papel de la ingeniería mecánica en la transición energética y una revisión de la política climática internacional.

Palabras clave: aprendizaje automático, consumo energético, emisiones de CO₂, análisis exploratorio de datos, Random Forest, Ridge, sostenibilidad, transición energética, Python.

Abstract

This Bachelor's Thesis presents an exploratory data analysis and machine learning-based prediction of global energy consumption and carbon emissions using a panel dataset covering 176 countries over the period 2000–2020. The study combines mechanical engineering, data science, and energy policy perspectives to provide a quantitative approach to energy transition challenges.

Two main datasets are used: the *Global Data on Sustainable Energy* (Kaggle, 2000–2020) as the primary source, and the *Our World in Data* (OWID) dataset for external validation. The methodology includes comprehensive exploratory analysis (univariate distributions, outlier detection, correlations, VIF-based multicollinearity analysis, and temporal analysis) followed by predictive modelling with two distinct models.

On the one hand, Model A predicts country-level CO₂ emissions using linear regression, Ridge, and Random Forest, achieving $R^2 = 0.91$ with Ridge after excluding fossil generation to avoid near-tautological prediction. On the other hand, Model B predicts per capita energy consumption, where Random Forest achieves $R^2 = 0.963$, capturing nonlinear relationships that linear models miss.

Additionally, an inter-dataset compatibility analysis is carried out, revealing systematic scale incompatibilities that make comparison between both datasets non-viable for this thesis, reframed as a substantive methodological finding nonetheless.

The work also includes socioeconomic contextualisation of the global energy landscape, the role of mechanical engineering in the energy transition, and a review of international climate policy.

Keywords: machine learning, energy consumption, CO₂ emissions, exploratory data analysis, Random Forest, Ridge, sustainability, energy transition, Python.

Índice general

Resumen	3
Abstract	5
Índice de figuras	14
Índice de tablas	15
Lista de acrónimos	17
1. Introducción	19
1.1. Motivación y contexto	19
1.2. Objetivos del trabajo	20
1.3. Metodología y fases del proyecto	20
1.4. Estructura de la memoria	21
2. Contexto socioeconómico, político y de ingeniería	23
2.1. Panorama energético mundial	23
2.1.1. El caso de España en el contexto europeo	25
2.2. Marco político y normativo	26
2.2.1. La Agenda 2030 y los Objetivos de Desarrollo Sostenible	26
2.2.2. El Acuerdo de París	27
2.2.3. El Pacto Verde Europeo	27
2.2.4. Normativas y estándares relevantes	28
2.3. El papel de la ingeniería mecánica en la transición energética	29
2.3.1. Diseño y optimización de sistemas energéticos	29
2.3.2. Eficiencia energética en la industria	30
2.3.3. Movilidad sostenible y almacenamiento de energía	30
2.3.4. La competencia digital del ingeniero mecánico	30
2.4. Estudio socioeconómico: desigualdad energética global	31
3. Antecedentes y estado del arte	33
3.1. Aprendizaje automático aplicado al sector energético	33
3.1.1. Predicción de la demanda energética	34
3.1.2. Predicción de emisiones de CO ₂	34
3.1.3. Optimización energética mediante IA	36

3.2.	Herramientas software y plataformas	37
3.3.	Trabajos previos en el departamento	37
4.	Fundamentos teóricos y tecnológicos	39
4.1.	El lenguaje Python	39
4.1.1.	Características principales	39
4.1.2.	Entorno de trabajo: Google Colab	39
4.2.	Librerías de Python utilizadas	40
4.2.1.	NumPy	40
4.2.2.	Pandas	40
4.2.3.	Matplotlib y Seaborn	40
4.2.4.	Scikit-learn	41
4.2.5.	Statsmodels	41
4.3.	Conceptos de aprendizaje automático	42
4.3.1.	Aprendizaje supervisado	42
4.3.2.	División del dataset: train/test temporal	42
4.3.3.	Estandarización de variables	43
4.4.	Algoritmos de regresión utilizados	43
4.4.1.	Regresión lineal múltiple	43
4.4.2.	Regresión Ridge	43
4.4.3.	Random Forest	44
4.5.	Métricas de evaluación	45
4.5.1.	Coeficiente de determinación (R^2)	45
4.5.2.	Error absoluto medio (MAE)	45
4.5.3.	Raíz del error cuadrático medio (RMSE)	45
4.5.4.	Diagnóstico de residuos	45
5.	Datos y fuentes de información	49
5.1.	Dataset principal: Global Data on Sustainable Energy	49
5.1.1.	Variables del dataset	50
5.1.2.	Decisiones de limpieza	50
5.2.	Dataset secundario: Our World in Data	51
5.3.	Otras fuentes de datos consultadas	51
6.	Análisis exploratorio de datos	53
6.1.	Inspección inicial del dataset	53
6.2.	Análisis univariado	54
6.2.1.	Distribución de emisiones de CO ₂	54
6.2.2.	Distribución del consumo energético per cápita	55
6.2.3.	Distribución del PIB per cápita	56

6.2.4.	Conclusión del análisis univariado	56
6.3.	Detección de outliers	57
6.3.1.	Boxplot de emisiones de CO ₂	57
6.3.2.	Boxplot de consumo energético per cápita	57
6.4.	Análisis bivariado y multivariado	58
6.4.1.	Análisis de correlaciones	58
6.4.2.	Detección de redundancia	59
6.4.3.	Selección inicial de variables por correlaciones	59
6.4.4.	Selección diferenciada de variables por modelo	60
6.4.5.	Verificación de multicolinealidad (VIF)	61
6.4.6.	Resumen del proceso de selección de variables	62
6.4.7.	Alternativa descartada: Análisis de Componentes Principales (PCA)	63
6.5.	Análisis temporal global	64
6.5.1.	Evolución de las emisiones globales de CO ₂	64
6.5.2.	Evolución de la cuota de energías renovables	65
6.5.3.	Comparación antes y después de 2015	66
7.	Modelado predictivo	67
7.1.	Modelo A: Predicción de emisiones de CO ₂	67
7.1.1.	Planteamiento y selección de variables	67
7.1.2.	Resultados con generación fósil	67
7.1.3.	Interpretación de coeficientes - Regresión Lineal	68
7.1.4.	Análisis de residuos - Regresión Lineal	69
7.1.5.	Decisión metodológica: exclusión de la generación fósil	70
7.1.6.	Resultados del modelo revisado (sin generación fósil)	70
7.2.	Modelo B: Predicción del consumo energético per cápita	71
7.2.1.	Planteamiento y selección de variables	71
7.2.2.	Regresión lineal	71
7.2.3.	Ridge	72
7.2.4.	Random Forest	72
7.2.5.	Comparación de modelos	72
7.2.6.	Importancia de variables - Random Forest	73
7.2.7.	Análisis de residuos - Regresión Lineal	74
7.3.	Discusión comparativa de modelos	74
8.	Validación externa y compatibilidad entre datasets	77
8.1.	Motivación	77
8.2.	Aplicación de los modelos al dataset de OWID	77
8.3.	Análisis de compatibilidad entre datasets	78

8.4. Diagnóstico: por qué fallaron las predicciones	79
8.5. Conclusión	79
9. Discusión de resultados	81
10. Conclusiones, limitaciones y líneas futuras	83
10.1. Conclusiones	83
10.2. Limitaciones	84
10.3. Líneas futuras de investigación	84
Bibliografía	85
A. Código Python completo	89
A.1. COMPRENSIÓN DEL PROBLEMA Y LOS DATOS	89
A.2. IMPORTACIÓN DE LIBRERÍAS	89
A.3. CARGA E INSPECCIÓN INICIAL	90
A.4. LIMPIEZA DE DATOS	91
A.5. ANÁLISIS UNIVARIADO	93
A.5.1. Distribución de emisiones de CO ₂	93
A.5.2. Distribución del consumo energético per cápita	93
A.5.3. Distribución del PIB per cápita	93
A.6. DETECCIÓN DE OUTLIERS	94
A.6.1. Boxplot de emisiones de CO ₂	94
A.6.2. Boxplot de consumo energético per cápita	94
A.7. ANÁLISIS BIVARIADO Y MULTIVARIADO	94
A.7.1. Análisis de correlaciones	94
A.7.2. Detección de redundancia entre variables	96
A.7.3. Análisis de multicolinealidad (VIF)	96
A.8. ANÁLISIS TEMPORAL GLOBAL	98
A.8.1. Evolución global de emisiones de CO ₂	98
A.8.2. Evolución global de la proporción de energías renovables	98
A.8.3. Referencia temporal: Acuerdo de París (2015)	99
A.8.4. Comparación antes y después de 2015	100
A.9. MODELADO PREDICTIVO – MODELO A: EMISIONES DE CO ₂	100
A.9.1. Preparación de datos	100
A.9.2. Regresión lineal múltiple	101
A.9.3. Ridge Regression	103
A.9.4. Random Forest	104
A.9.5. Modelo CO ₂ revisado — sin generación fósil	106

A.10.MODELADO PREDICTIVO – MODELO B: CONSUMO	
ENERGÉTICO PER CÁPITA	109
A.10.1. Preparación de datos	109
A.10.2. Regresión lineal múltiple	109
A.10.3. Ridge Regression	111
A.10.4. Random Forest	112
A.11.VALIDACIÓN EXTERNA	113
A.11.1. Análisis de compatibilidad entre datasets	113

Índice de figuras

2.1. Evolución del consumo mundial de energía primaria por regiones (1990–2024), en Mtoe. Fuente: Enerdata [2].	24
2.2. Emisiones globales de gases de efecto invernadero por sector y uso final (2021). El sector energético concentra el 75,7% del total. Fuente: Climate Watch / World Resources Institute [1]. Disponible en versión interactiva en https://www.wri.org/insights/4-charts-explain-greenhouse-gas-emissions-countries-and-sectors	25
2.3. Estructura de generación de energía eléctrica en España en 2024. Fuente: Red Eléctrica de España [5].	26
2.4. Objetivos de Desarrollo Sostenible número 7, 9 y 13. Fuente: Naciones Unidas [6].	27
2.5. Objetivos del Pacto Verde Europeo. Fuente: La Moncloa / Gobierno de España [9].	28
2.6. Parque eólico de la Central Hidroeólica de El Hierro (Islas Canarias). Fuente: Wikipedia [13]. Licencia CC BY-SA.	29
2.7. Estación de carga para vehículos eléctricos en Málaga. Fuente: Wikimedia Commons [14]. Licencia CC BY-SA.	31
2.8. Representación esquemática de la curva de Kuznets ambiental: relación en forma de U invertida entre renta per cápita y degradación ambiental. Elaboración propia a partir de [17].	32
3.1. Mapa de selección de algoritmos de <i>machine learning</i> de Scikit-learn. La rama de <i>regression</i> (parte superior derecha del diagrama) corresponde a la familia de problemas abordados en este TFG. Fuente: Scikit-learn [19]. Disponible en versión interactiva en https://scikit-learn.org/stable/machine_learning_map.html	33
3.2. Evolución de los factores de la identidad de Kaya a nivel mundial (1965–2024). Se representa el cambio porcentual acumulado de cada factor respecto al año base. Elaboración: Our World in Data [24]. Licencia CC BY. Disponible como gráfica interactiva con filtros por países en https://ourworldindata.org/grapher/kaya-identity-co2	35
4.1. Logotipos de Python [35] y Google Colaboratory [36], las herramientas principales de desarrollo de este TFG.	40

4.2. Logotipos de las librerías de Python utilizadas en este TFG: NumPy [37], Pandas [38], Matplotlib [39], Seaborn [40], Scikit-learn [19] y Statsmodels [41].	42
6.1. Distribución de emisiones de CO ₂ (kt).	54
6.2. Distribución del consumo energético per cápita (kWh/persona). . . .	55
6.3. Distribución del PIB per cápita (USD).	56
6.4. Boxplot de emisiones de CO ₂	57
6.5. Boxplot de consumo energético per cápita.	57
6.6. Mapa de calor de correlaciones.	58
6.7. Emisiones globales de CO ₂ (2000–2019).	64
6.8. Proporción media de energías renovables en el consumo final.	65
7.1. Residuos del modelo lineal de CO ₂ (con generación fósil).	69
7.2. Residuos de la regresión lineal del modelo de energía per cápita. . . .	74

Índice de tablas

5.1. Variables del dataset principal y su descripción.	50
6.1. Estructura del dataset: variables, tipos de datos y completitud.	53
6.2. Valores VIF – Modelo de emisiones de CO ₂	61
6.3. Valores VIF – Modelo de energía per cápita (sin Year).	62
7.1. Comparación de modelos – Modelo A con generación fósil.	67
7.2. Coeficientes de la regresión lineal del Modelo A con generación fósil (variables estandarizadas).	68
7.3. Comparación de modelos – Modelo A sin generación fósil.	70
7.4. Comparación de modelos – Modelo B de consumo energético per cápita.	72
7.5. Importancia de variables – Random Forest (consumo per cápita). . .	73
8.1. Comparación de variables entre datasets (año 2019) – Muestra de países.	78

Lista de acrónimos

CO ₂	Dióxido de carbono
EDA	<i>Exploratory Data Analysis</i> (Análisis exploratorio de datos)
EKC	<i>Environmental Kuznets Curve</i> (Curva de Kuznets ambiental)
FEM	<i>Finite Element Method</i> (Método de elementos finitos)
CFD	<i>Computational Fluid Dynamics</i> (Dinámica de fluidos computacional)
GEI	Gases de efecto invernadero
IDAE	Instituto para la Diversificación y Ahorro de la Energía
IEA	<i>International Energy Agency</i> (Agencia Internacional de la Energía)
INE	Instituto Nacional de Estadística
IQR	<i>Interquartile Range</i> (Rango intercuartílico)
KDE	<i>Kernel Density Estimation</i> (Estimación de densidad por núcleos)
LSTM	<i>Long Short-Term Memory</i>
MAE	<i>Mean Absolute Error</i> (Error absoluto medio)
ML	<i>Machine Learning</i> (Aprendizaje automático)
ODS	Objetivos de Desarrollo Sostenible
OLS	<i>Ordinary Least Squares</i> (Mínimos cuadrados ordinarios)
OWID	<i>Our World in Data</i>
PCA	<i>Principal Component Analysis</i> (Análisis de componentes principales)
PIB	Producto Interior Bruto
PNIEC	Plan Nacional Integrado de Energía y Clima
PPA	Paridad de poder adquisitivo
PUE	<i>Power Usage Effectiveness</i> (Efectividad de uso de la energía)
RMSE	<i>Root Mean Square Error</i> (Raíz del error cuadrático medio)
R ²	Coeficiente de determinación
TFG	Trabajo de Fin de Grado
VIF	<i>Variance Inflation Factor</i> (Factor de inflación de la varianza)

Capítulo 1

Introducción

1.1. Motivación y contexto

El sistema energético mundial se encuentra en un punto de inflexión. El sector energético es responsable de más del 75 % de las emisiones globales de gases de efecto invernadero, según datos de Climate Watch y el World Resources Institute [1]. A su vez, la demanda energética global no ha dejado de crecer. Según *Global Energy & Climate Data* de Enerdata, el consumo energético global creció en un 2,2 % en 2024, superando la tendencia entre 2010 y 2019 del 1,5 % anual, impulsado especialmente por los países BRICS, que en 2024 concentraban ya el 43 % del consumo global [2].

Ante este escenario, la transición hacia un modelo energético sostenible se ha convertido en uno de los retos más relevantes de la actualidad. Así pues, medidas como el Acuerdo de París (2015), el Pacto Verde Europeo y los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 configuran un marco de gobernanza global que exige herramientas cuantitativas para comprender, predecir y gestionar el consumo energético y sus impactos ambientales.

En este contexto, la ciencia de datos y el aprendizaje automático (*machine learning*) ofrecen una gran oportunidad: la capacidad de extraer patrones de conjuntos masivos de datos, construir modelos predictivos y generar conocimiento accionable a partir de información compleja y multidimensional. La combinación de estas técnicas con el análisis de datos energéticos permite abordar preguntas que van desde la identificación de los factores que más influyen en las emisiones de CO₂, hasta la predicción del consumo energético per cápita en función de variables socioeconómicas.

Este Trabajo de Fin de Grado nace de la confluencia de dos motivaciones. Por un lado, el interés por aplicar metodologías de análisis de datos a un problema de enorme relevancia socioeconómica y ambiental. Por otro, el reto académico de adquirir competencias en lenguaje Python y aprendizaje automático, disciplinas que no forman parte del currículo estándar del Grado en Ingeniería Mecánica pero cuyo dominio resulta cada vez más valioso para el ingeniero del siglo XXI.

1.2. Objetivos del trabajo

El objetivo general del presente TFG es realizar un análisis exploratorio y predictivo del consumo energético y las tendencias de sostenibilidad globales mediante técnicas de aprendizaje automático.

Para alcanzar este objetivo general, se definen los siguientes objetivos específicos:

- OE.1 Realizar un análisis exploratorio exhaustivo del dataset *Global Data on Sustainable Energy* (2000–2020), incluyendo la inspección de distribuciones, la detección de outliers, el estudio de correlaciones y la evaluación de multicolinealidad, entre otros.
- OE.2 Desarrollar un modelo predictivo (Modelo A) para estimar las emisiones de CO₂ por país y año, evaluando regresión lineal, Ridge y Random Forest.
- OE.3 Desarrollar un segundo modelo predictivo (Modelo B) para estimar el consumo energético per cápita, comparando las mismas familias de algoritmos.
- OE.4 Analizar la evolución temporal del sistema energético global y contextualizar los resultados en el marco de la política climática internacional.
- OE.5 Evaluar la viabilidad de una validación externa utilizando el dataset de *Our World in Data*, para comparar las predicciones de los modelos con los datos reales ya publicados, del 2020 en adelante.
- OE.6 Contextualizar el trabajo desde la perspectiva de la ingeniería mecánica, analizando el papel de esta disciplina en la transición energética.

1.3. Metodología y fases del proyecto

El desarrollo del trabajo se ha organizado en las siguientes fases:

- Fase 1. Formación en programación y ciencia de datos:** aprendizaje desde cero del lenguaje Python y sus principales librerías de análisis de datos y visualización (NumPy, Pandas, Matplotlib, Seaborn), así como de los fundamentos de *machine learning*, con especial atención a los problemas de regresión supervisada. Esta formación se realizó bajo supervisión de la tutora, principalmente mediante material online y libros relacionados.
- Fase 2. Selección del dataset y definición del alcance:** en coordinación con la tutora, se evaluaron distintas fuentes de datos energéticos globales y se seleccionó el

dataset *Global Data on Sustainable Energy* de Kaggle (2000–2020) por su amplia cobertura temporal, geográfica y temática.

- Fase 3. Revisión bibliográfica y contextualización:** estudio de fuentes estadísticas (IEA, IDAE, Enerdata, OWID), normativa y política energética, y revisión de trabajos previos que aplican aprendizaje automático.
- Fase 4. Adquisición y preparación de datos:** obtención de los datasets, limpieza, estandarización de nombres, tratamiento de valores faltantes y exclusión del año 2020 por falta de cobertura.
- Fase 5. Análisis exploratorio de datos (EDA):** análisis univariado, bivariado y multivariado, incluyendo estudio de correlaciones, detección de redundancias y análisis VIF.
- Fase 6. Análisis temporal:** evolución de las emisiones de CO₂ y de la cuota renovable global, con referencia al Acuerdo de París.
- Fase 7. Modelado predictivo:** construcción, entrenamiento y evaluación de los Modelos A y B con división temporal del dataset (2000–2015 entrenamiento, 2016–2019 test).
- Fase 8. Validación externa:** análisis de compatibilidad entre los datasets de Kaggle y OWID.
- Fase 9. Documentación:** redacción de la memoria en $\text{\LaTeX}$ y preparación de la defensa.

1.4. Estructura de la memoria

La presente memoria se organiza en los siguientes capítulos:

- **Capítulo 1 — Introducción:** presenta la motivación, los objetivos, la metodología y la estructura del trabajo.
- **Capítulo 2 — Contexto socioeconómico, político y de ingeniería:** ofrece una visión del panorama energético mundial, el marco normativo internacional y europeo, y el papel de la ingeniería mecánica en la transición energética.
- **Capítulo 3 — Antecedentes y estado del arte:** revisión de trabajos previos que aplican *machine learning* al sector energético, las herramientas software que están siendo utilizadas en la actualidad y los antecedentes en el departamento.
- **Capítulo 4 — Fundamentos teóricos y tecnológicos:** describe el lenguaje Python, las librerías empleadas, los algoritmos de regresión, las métricas de evaluación y los tests de diagnóstico de residuos.

- **Capítulo 5 — Datos y fuentes de información:** detalla los datasets utilizados, las variables disponibles y las decisiones de limpieza adoptadas.
- **Capítulo 6 — Análisis exploratorio de datos:** presenta el análisis univariado, la detección de outliers, el estudio de correlaciones, el análisis VIF, la selección de variables y el análisis temporal global.
- **Capítulo 7 — Modelado predictivo:** desarrolla los Modelos A (emisiones de CO₂) y B (consumo per cápita), comparando regresión lineal, Ridge y Random Forest.
- **Capítulo 8 — Validación externa y compatibilidad entre datasets:** analiza la viabilidad de la validación externa con datos de OWID y documenta las incompatibilidades encontradas.
- **Capítulo 9 — Discusión de resultados:** interpreta los hallazgos del trabajo desde una perspectiva integrada.
- **Capítulo 10 — Conclusiones, limitaciones y líneas futuras:** sintetiza las conclusiones principales, reconoce las limitaciones y propone direcciones de trabajo futuro.

La memoria incluye además la bibliografía y un anexo final con el código Python del notebook trabajado en Google Colab.

Capítulo 2

Contexto socioeconómico, político y de ingeniería

2.1. Panorama energético mundial

El consumo de energía primaria a nivel global ha experimentado un crecimiento sostenido durante las dos primeras décadas del siglo XXI, con una aceleración especialmente marcada en las economías emergentes, como ya se mencionó con anterioridad. Este crecimiento ha estado impulsado, en gran medida, por el aumento de la población, la urbanización y el desarrollo industrial en estas regiones.

Este incremento ha sido, por tanto, desigual: mientras las economías de la OCDE han tendido a estabilizar o reducir ligeramente su consumo per cápita, las regiones de Asia-Pacífico, con China e India a la cabeza, han multiplicado su demanda energética debido a su rápido crecimiento económico. En menor medida, otras regiones como Oriente Medio, África y América Latina también han contribuido a este aumento, aunque con ritmos más moderados.

La Figura 2.1, elaborada a partir de los datos del anuario estadístico *Global Energy & Climate Data* de Enerdata, ilustra muy bien esta tendencia en el consumo desglosada por grandes regiones: Europa, la CIS (Comunidad de Estados Independientes, CEI en español, que agrupa a antiguas repúblicas soviéticas, incluida Rusia), Norteamérica, Latinoamérica, Asia, Pacífico, África y Oriente Medio. En ella puede observarse la tendencia del consumo de energía primaria, expresado en megatoneladas equivalentes de petróleo (Mtoe), a lo largo del periodo comprendido entre 1990 y 2024.

World

Trend over 1990 - 2024 - Mtoe

Benchmark countries





Figura 2.1: Evolución del consumo mundial de energía primaria por regiones (1990–2024), en Mtoe. Fuente: Enerdata [2].

Además, la matriz energética global sigue dominada por los combustibles fósiles. Según el capítulo *Pathways for the energy mix* del *World Energy Outlook 2024* de la IEA, los combustibles fósiles aún cubrían el 80 % de la demanda energética global en 2023, si bien las proyecciones indican que la demanda de los tres combustibles fósiles alcanzará su pico antes de 2030 [3]. Las energías renovables, pese a su crecimiento acelerado en la última década (especialmente la eólica y la solar fotovoltaica), aún representaban una fracción relativamente modesta del mix global. La Figura 2.2 muestra la distribución de las emisiones globales de GEI por sector y uso final para el año 2021.

Global greenhouse gas emissions by sector and end use, 2023



Click on or hover over chart sections for a closer look.
Source: [Climate Watch](#).




Figura 2.2: Emisiones globales de gases de efecto invernadero por sector y uso final (2021). El sector energético concentra el 75,7% del total. Fuente: Climate Watch / World Resources Institute [1]. Disponible en versión interactiva en <https://www.wri.org/insights/4-charts-explain-greenhouse-gas-emissions-countries-and-sectors>.

2.1.1. El caso de España en el contexto europeo

España se sitúa como un actor relevante en la transición energética europea. La actualización del Plan Nacional Integrado de Energía y Clima (PNIEC) 2023–2030, aprobada por Real Decreto 986/2024 de 24 de septiembre, eleva los objetivos respecto a la versión firmada en 2020: un 48 % de cuota renovable sobre el consumo final de energía, un 81 % de generación eléctrica renovable y una reducción del 32 % en las emisiones de GEI respecto a 1990 [4]. Según los informes de Red Eléctrica, en 2023 la generación renovable superó el 50 % del *mix* eléctrico nacional por primera vez en la historia (50,3 %), y en 2024 alcanzó un récord del 56,8 %, con 148.999 GWh producidos [5]. La Figura 2.3 muestra la estructura del *mix* eléctrico español en 2024.

Estructura de generación de energía eléctrica (%) en 2024 en España



(1) Incluye biogás, biomasa, geotérmica, hidráulica marina, hidroeléctrica y residuos renovables.

Figura 2.3: Estructura de generación de energía eléctrica en España en 2024. Fuente: Red Eléctrica de España [5].

Por su parte, el Instituto para la Diversificación y Ahorro de la Energía (IDAE) y el Instituto Nacional de Estadística (INE) proporcionan balances energéticos sectoriales que permiten analizar el consumo por usos finales: industria, transporte, residencial y servicios. Estas fuentes resultan complementarias al análisis global que se desarrolla en este TFG y pueden servir de base para futuras investigaciones a escala nacional.

2.2. Marco político y normativo

2.2.1. La Agenda 2030 y los Objetivos de Desarrollo Sostenible

En 2015, la Asamblea General de las Naciones Unidas aprobó la Agenda 2030 para el Desarrollo Sostenible, que establece 17 Objetivos de Desarrollo Sostenible (ODS) y 169 metas asociadas [6]. Este TFG se alinea especialmente con tres de ellos (Figura 2.4):

- **ODS 7 — Energía asequible y no contaminante:** garantizar el acceso a una energía asequible, segura, sostenible y moderna para todos.
- **ODS 9 — Industria, innovación e infraestructura:** promover la industrialización inclusiva y sostenible y fomentar la innovación.
- **ODS 13 — Acción por el clima:** adoptar medidas urgentes para combatir el cambio climático y sus efectos.



Figura 2.4: Objetivos de Desarrollo Sostenible número 7, 9 y 13. Fuente: Naciones Unidas [6].

2.2.2. El Acuerdo de París

El Acuerdo de París, adoptado en la Conferencia de las Naciones Unidas sobre el Cambio Climático de 2015 (Vigésima primera Conferencia de las Partes, COP21), es el principal tratado internacional para la lucha contra el cambio climático. Su objetivo central es limitar el calentamiento global muy por debajo de 2, preferiblemente a 1,5 °C por encima de los niveles preindustriales, y alcanzar la neutralidad de carbono a escala global para mediados de siglo [7].

En el análisis temporal desarrollado en el Capítulo 6, se toma como referencia el año 2015, momento en que se firmó el acuerdo, con el objetivo de evaluar si los datos reflejan un posible cambio de tendencia a partir de entonces, aunque su entrada en vigor no tuvo lugar hasta el 4 de noviembre de 2016.

El Acuerdo de París constituye un punto de inflexión en la acción multilateral frente al cambio climático, ya que, por primera vez, establece un marco vinculante en el que todos los países se comprometen a actuar de forma conjunta, impulsando medidas ambiciosas tanto para mitigar sus efectos como para adaptarse a ellos.

2.2.3. El Pacto Verde Europeo

El Pacto Verde Europeo (*European Green Deal*), presentado por la Comisión Europea en diciembre de 2019, establece una hoja de ruta para la descarbonización de la economía de la UE. Entre sus objetivos se incluye la reducción de al menos un 55 % de las emisiones netas de GEI para 2030 respecto a 1990 y la neutralidad climática para 2050 [8]. Este marco tiene implicaciones directas para la industria y la ingeniería mecánica, ya que exige transformaciones profundas en los procesos productivos, la eficiencia de los equipos y la integración de tecnologías limpias. La Figura 2.5 resume los objetivos principales de esta iniciativa.




Figura 2.5: Objetivos del Pacto Verde Europeo. Fuente: La Moncloa / Gobierno de España [9].

2.2.4. Normativas y estándares relevantes

A nivel de gestión corporativa y empresarial, varios estándares internacionales resultan relevantes para el ámbito de este estudio:

- **ISO 14001** — Sistemas de gestión ambiental, que establece requisitos para implementar una política de mejora continua y prevención de la contaminación [10].
- **ISO 50001** — Sistemas de gestión de la energía, orientada a la reducción del consumo y la mejora de la eficiencia energética en organizaciones [11].
- **GHG Protocol** — Marco de referencia para la contabilización y reporte de emisiones de gases de efecto invernadero, clasificadas en tres alcances (directas, indirectas por electricidad e indirectas de la cadena de valor) [12].

2.3. El papel de la ingeniería mecánica en la transición energética

La ingeniería mecánica ocupa una posición central en la transición energética por su implicación directa en el diseño, la fabricación y la optimización de los sistemas que producen, transforman, almacenan y consumen energía. A continuación se destacan algunas de las áreas más relevantes.

2.3.1. Diseño y optimización de sistemas energéticos

El ingeniero mecánico participa en el diseño de turbinas eólicas, sistemas de energía solar térmica, intercambiadores de calor y sistemas de cogeneración, entre otros. La optimización termodinámica y fluidodinámica de estos equipos es esencial para maximizar los rendimientos de conversión y minimizar las pérdidas. Un ejemplo representativo es la Central Hidroeólica de El Hierro [13] (Figura 2.6), un proyecto pionero que combina un parque eólico de 11,5 MW con una central hidroeléctrica de bombeo de 11,3 MW, con el objetivo de cubrir la demanda eléctrica de la isla íntegramente con fuentes renovables. En este contexto, las técnicas de aprendizaje automático complementan las herramientas tradicionales de simulación (CFD, FEM) para identificar configuraciones óptimas a partir de datos experimentales.



Figura 2.6: Parque eólico de la Central Hidroeólica de El Hierro (Islas Canarias). Fuente: Wikipedia [13]. Licencia CC BY-SA.

2.3.2. Eficiencia energética en la industria

El sector industrial es, junto con el transporte, uno de los principales consumidores de energía final a nivel global. La ingeniería mecánica contribuye a la eficiencia energética industrial mediante el diseño de procesos térmicos optimizados, la recuperación de calor residual, la selección de materiales con mejor comportamiento térmico y la automatización de procesos. El mantenimiento predictivo, donde se aplican técnicas de *machine learning* similares a las de este TFG, permite anticipar fallos en equipos rotativos y reducir paradas no planificadas, con el consiguiente ahorro energético.

2.3.3. Movilidad sostenible y almacenamiento de energía

El diseño de vehículos eléctricos, sistemas de almacenamiento de energía (baterías, hidrógeno, almacenamiento térmico) y redes de distribución inteligentes son áreas donde la ingeniería mecánica interactúa con la electrónica, la informática y la ciencia de materiales. La electrificación del transporte, cuya infraestructura de recarga se extiende ya a ciudades como Málaga (Figura 2.7), es un ejemplo de cómo estas disciplinas convergen. Comprender los factores que determinan el consumo energético a escala macroeconómica, como se analiza en este trabajo, proporciona al ingeniero mecánico una visión sistémica necesaria para diseñar soluciones verdaderamente sostenibles.

2.3.4. La competencia digital del ingeniero mecánico

El dominio de herramientas de programación y análisis de datos se ha convertido en una competencia cada vez más demandada en el perfil del ingeniero mecánico. Lenguajes como Python, junto con librerías de machine learning y visualización de datos, permiten al ingeniero abordar problemas complejos de optimización, mantenimiento predictivo, control de calidad y análisis energético.

Por ejemplo, estas herramientas facilitan el tratamiento de grandes volúmenes de información procedente de sensores y sistemas industriales, lo que resulta clave en entornos de industria avanzada. Considerando esto, la capacidad de extraer conocimiento a partir de los datos y apoyar la toma de decisiones técnicas se consolida como un elemento diferenciador en el ejercicio profesional del ingeniero mecánico.



Figura 2.7: Estación de carga para vehículos eléctricos en Málaga. Fuente: Wikimedia Commons [14]. Licencia CC BY-SA.

2.4. Estudio socioeconómico: desigualdad energética global

Las desigualdades en el consumo energético per cápita constituyen uno de los indicadores más reveladores de la brecha de desarrollo económico a nivel mundial. Mientras un ciudadano medio de Islandia o Catar consume más de 100.000 kWh al año, en muchos países del África subsahariana esta cifra no alcanza los 1.000 kWh [15]. Esta disparidad, que se analiza cuantitativamente en el Capítulo 6, tiene raíces profundas en la historia colonial, la dotación de recursos naturales, las decisiones de política energética y el grado de industrialización.

El PIB per cápita emerge como el predictor más potente del consumo energético per cápita en los modelos desarrollados en este trabajo (Capítulo 7), lo que confirma la fuerte vinculación entre desarrollo económico y uso de energía. Sin embargo, la relación no es lineal: los países de alto desarrollo tienden a estabilizar o incluso reducir su intensidad energética (energía por unidad de PIB), mientras que las economías en crecimiento experimentan un aumento proporcional al ritmo de su industrialización.

Este patrón se corresponde con la hipótesis de la **curva de Kuznets ambiental** (*Environmental Kuznets Curve*, EKC). El economista Simon Kuznets propuso originalmente en 1955 una relación en forma de U invertida entre la renta per cápita y la desigualdad económica [16]. En la década de 1990, Grossman y Krueger aplicaron

esta idea al ámbito ambiental, postulando que la degradación ambiental (medida, por ejemplo, en emisiones de CO₂ o consumo energético por unidad de PIB) primero aumenta con el crecimiento económico, alcanza un máximo y después disminuye a medida que las economías se desarrollan, se terciarizan e invierten en tecnologías más eficientes [17]. La Figura 2.8 ilustra esta relación teórica.




Figura 2.8: Representación esquemática de la curva de Kuznets ambiental: relación en forma de U invertida entre renta per cápita y degradación ambiental. Elaboración propia a partir de [17].

En la práctica, la evidencia empírica sobre la EKC es mixta: la forma de U invertida se observa para algunos contaminantes (como el SO₂ o las partículas en suspensión) pero es menos clara para las emisiones de CO₂ y el consumo energético total, donde muchos países desarrollados aún no han alcanzado el punto de inflexión [18]. No obstante, el concepto resulta muy útil como marco interpretativo para este TFG, ya que ayuda a explicar por qué el Random Forest ofrece mejores resultados que la regresión lineal o Ridge a la hora de capturar la relación entre PIB per cápita y consumo energético: la no linealidad de esta relación (crecimiento rápido a rentas bajas, saturación a rentas altas) es exactamente el tipo de patrón que los árboles de decisión pueden modelar mediante sus particiones sucesivas del espacio de variables.

Finalmente, este análisis tiene implicaciones directas para la política energética: cualquier estrategia de descarbonización global debe tener en cuenta que limitar el acceso a la energía en países en desarrollo entraría en conflicto con el ODS 7 y con los principios de equidad que fundamentan el Acuerdo de París.

Capítulo 3

Antecedentes y estado del arte

3.1. Aprendizaje automático aplicado al sector energético

La aplicación de técnicas de *machine learning* al ámbito energético ha experimentado un crecimiento exponencial en la última década. La Figura 3.1 ofrece una visión general de las familias de algoritmos disponibles en Scikit-learn, la librería utilizada en este TFG, y del proceso de decisión para seleccionar el más adecuado en función del tipo de problema y del tamaño del dataset. De entre todas las ramas del diagrama, la que corresponde a este TFG es la de *regression* (regresión), que agrupa los algoritmos empleados para predecir variables numéricas continuas.




Figura 3.1: Mapa de selección de algoritmos de *machine learning* de Scikit-learn. La rama de *regression* (parte superior derecha del diagrama) corresponde a la familia de problemas abordados en este TFG. Fuente: Scikit-learn [19]. Disponible en versión interactiva en https://scikit-learn.org/stable/machine_learning_map.html.

3.1.1. Predicción de la demanda energética

La predicción de la demanda eléctrica a corto, medio y largo plazo es una de las aplicaciones más maduras del *machine learning* en el sector energético. Zhao y Magoulès (2012) realizaron una revisión de los principales métodos de predicción del consumo en edificios, identificando tres grandes familias: los métodos de ingeniería (simulaciones físicas detalladas), los métodos estadísticos (regresión, series temporales) y los métodos basados en inteligencia artificial (redes neuronales, máquinas de vectores de soporte) [20]. Su trabajo, publicado en *Renewable and Sustainable Energy Reviews*, mostró que los métodos basados en IA ofrecían ventajas en cuanto a adaptabilidad y capacidad de captura de relaciones no lineales, aunque con mayores requisitos de datos.

Más recientemente, Mishra, Lone y Mishra (2024) propusieron DECODE, un modelo basado en redes LSTM (*Long Short-Term Memory*) para la predicción del consumo energético en edificios residenciales y comerciales [21]. El modelo emplea datos históricos de consumo, patrones de ocupación y condiciones meteorológicas como variables de entrada, y lo comparan con métodos clásicos como la regresión lineal, los árboles de decisión y Random Forest. Los resultados muestran que el modelo LSTM alcanza un R^2 de 0,97, superando a los enfoques convencionales. Este trabajo, publicado en *Energy and Buildings* (vol. 307), es especialmente relevante para el presente TFG porque utiliza varios de los mismos algoritmos base (regresión lineal y Random Forest) como referencia de comparación.

3.1.2. Predicción de emisiones de CO₂

En el ámbito macroeconómico, diversos trabajos han empleado modelos de regresión y *ensemble methods* para predecir emisiones de CO₂ a nivel país. El marco conceptual más utilizado para este tipo de análisis es la identidad de Kaya [22], una descomposición algebraica adoptada por el IPCC (*Intergovernmental Panel on Climate Change*, Panel Intergubernamental sobre el Cambio Climático) en sus informes de evaluación [23] que expresa las emisiones de CO₂ como el producto de cuatro factores, tal como se muestra en la Ecuación 3.1.

$$\text{CO}_2 = P \times \frac{G}{P} \times \frac{E}{G} \times \frac{F}{E} \quad (3.1)$$

donde P es la población, G/P el PIB per cápita, E/G la intensidad energética del PIB (energía consumida por unidad de PIB) y F/E la intensidad de carbono de la energía (emisiones por unidad de energía consumida). Esta descomposición permite

identificar qué factores están impulsando o frenando las emisiones en cada país y periodo.

La Figura 3.2 muestra la evolución histórica de los cuatro factores de Kaya a nivel mundial desde 1965. Se observa que tanto la población como el PIB per cápita han crecido de forma sostenida (más del doble y del triple respectivamente), lo que ha impulsado al alza las emisiones de CO₂. Sin embargo, la intensidad energética (energía por unidad de PIB) y la intensidad de carbono (emisiones por unidad de energía) han descendido de forma continua, actuando como factores de contención. El resultado neto es que las emisiones globales se han multiplicado por más de 2,5 veces desde 1965, ya que el efecto del crecimiento económico y demográfico ha superado las ganancias de eficiencia.




Figura 3.2: Evolución de los factores de la identidad de Kaya a nivel mundial (1965–2024). Se representa el cambio porcentual acumulado de cada factor respecto al año base. Elaboración: Our World in Data [24]. Licencia CC BY. Disponible como gráfica interactiva con filtros por países en <https://ourworldindata.org/grapher/kaya-identity-co2>.

Los modelos desarrollados en este TFG están alineados con esta descomposición conceptual: las variables predictoras seleccionadas (PIB per cápita, intensidad energética, generación eléctrica por fuente y cuota renovable) corresponden

directamente a los factores de la identidad de Kaya o a indicadores estrechamente relacionados con ellos.

3.1.3. Optimización energética mediante IA

A nivel corporativo, varias empresas tecnológicas aplican técnicas de *machine learning* para la optimización energética en tiempo real. Se destacan tres ejemplos representativos:

- **Google (DeepMind):** en 2016, el equipo de DeepMind desarrolló un sistema de redes neuronales entrenado con datos de miles de sensores (temperaturas, velocidades de bombas, consumos) de los centros de datos de Google. El sistema predice las condiciones de temperatura y presión en la hora siguiente y recomienda ajustes en los equipos de refrigeración. El resultado fue una reducción del 40 % en la energía destinada a refrigeración, lo que se tradujo en una mejora del 15 % en la eficiencia energética global de las instalaciones, medida como PUE (*Power Usage Effectiveness*) [25].
- **Tesla (Opticaster):** Opticaster es el software de optimización inteligente de Tesla diseñado para maximizar los beneficios económicos y los objetivos de sostenibilidad de los recursos energéticos distribuidos. Los gestores de instalaciones, propietarios de empresas y promotores de energías renovables utilizan Opticaster para reducir el gasto energético, aumentar el consumo de energía renovable y suministrar energía limpia a la red en momentos de necesidad. Según la página de soporte de Tesla, Opticaster acumula más de cien millones de horas de experiencia operativa y ha generado decenas de millones de dólares en ahorro de costes operativos e ingresos por servicios a la red para miles de clientes en todo el mundo [26].
- **Schneider Electric (EcoStruxure):** la plataforma EcoStruxure de Schneider Electric integra soluciones de IA y *machine learning* para la gestión energética en edificios, centros de datos e industria. En particular, su módulo *EcoStruxure Industrial Advisor – Predictive Energy* emplea modelos de aprendizaje predictivo para optimizar el consumo de los sistemas auxiliares de las plantas industriales (producción de agua refrigerada, generación de vapor, etc.), que típicamente representan el 50 % del consumo total de una planta. Según el blog técnico de Schneider Electric, esta solución permite reducir el consumo energético de los sistemas auxiliares hasta en un 10 % y las emisiones de carbono asociadas hasta en un 40 %, con un retorno de la inversión inferior a tres meses [27].

3.2. Herramientas software y plataformas

El ecosistema de herramientas para análisis de datos energéticos es amplio. Se destacan las más relevantes:

- **Python y su ecosistema científico** (NumPy, Pandas, Scikit-learn, Matplotlib, Seaborn): constituyen el estándar de facto para el análisis de datos y el *machine learning* en el ámbito académico e investigador. Es la herramienta principal de este TFG.
- **Google Colab**: plataforma cloud que permite ejecutar notebooks de Python con acceso gratuito a GPUs, utilizada como entorno de desarrollo en este trabajo.
- **Plataformas de datos abiertos**: Kaggle, Our World in Data, datos.gob.es y ESIOS de Red Eléctrica ofrecen datasets energéticos procesados y listos para el análisis.
- **Software de gestión energética empresarial**: plataformas como Spacewell Energy (Dexma), EnergyCAP o Desigo CC de Siemens integran Big Data e IA para la monitorización y optimización del consumo en tiempo real [28–30].

3.3. Trabajos previos en el departamento

Este TFG se enmarca dentro de una línea de trabajos que aplican técnicas de aprendizaje automático en el ámbito de la ingeniería industrial. En el mismo departamento, Cruces Pérez (2025) desarrolló un estudio de mantenimiento predictivo de un motor turbofán mediante regresión lineal, Random Forest, SVM y KNN [31], mientras que Robles de Molina (2025) aplicó aprendizaje por refuerzo profundo a datos de sensores industriales [32]. Loring Bueno (2025) empleó redes neuronales convolucionales para la detección de defectos en superficies fabricadas por manufactura aditiva [33]. Estos trabajos comparten con el presente TFG el denominador común de aplicar técnicas de *machine learning* a problemas de ingeniería, aunque difieren en el dominio de aplicación.

En el ámbito de la optimización energética, Infante Fernández (2025) (Universidad Politécnica de Madrid) desarrolló un sistema predictivo para el consumo energético en entornos empresariales utilizando seis modelos de aprendizaje supervisado (regresión lineal, Random Forest, MLP, XGBoost, LightGBM y CatBoost) sobre el dataset *Appliances Energy Prediction* [34]. Su enfoque se centra en el consumo a nivel

de edificio, mientras que el presente trabajo opera a escala macroeconómica y con un enfoque más analítico que operacional.

Capítulo 4

Fundamentos teóricos y tecnológicos

4.1. El lenguaje Python

Python es un lenguaje de programación interpretado, de alto nivel y de propósito general, creado por Guido van Rossum y publicado por primera vez en 1991. Se ha convertido en el lenguaje dominante en ciencia de datos, *machine learning* e inteligencia artificial gracias a su sintaxis clara, su amplio ecosistema de librerías y su comunidad activa [35].

4.1.1. Características principales

- **Tipado dinámico:** las variables no requieren declaración de tipo, lo que agiliza la escritura de código.
- **Orientación a objetos:** soporta paradigmas de programación orientada a objetos, funcional e imperativa.
- **Interpretado:** el código se ejecuta línea a línea, lo que facilita la exploración interactiva de datos.
- **Extensibilidad:** sus funcionalidades se amplían fácilmente mediante paquetes (librerías de código reutilizable) instalables a través de pip, el gestor de paquetes estándar de Python.

4.1.2. Entorno de trabajo: Google Colab

Google Colaboratory (Colab) es un servicio gratuito de Google que permite ejecutar notebooks de Jupyter en la nube, con acceso a hardware acelerado (GPU/TPU). Cada notebook organiza el código en celdas que pueden ser de tipo código o texto (Markdown), lo que resulta ideal para combinar análisis, visualización y documentación en un mismo documento. La Figura 4.1 muestra los logotipos de ambas herramientas.



Figura 4.1: Logotipos de Python [35] y Google Colaboratory [36], las herramientas principales de desarrollo de este TFG.

4.2. Librerías de Python utilizadas

4.2.1. NumPy

NumPy (*Numerical Python*) es la librería fundacional para la computación numérica en Python. Proporciona el objeto `ndarray`, un arreglo multidimensional homogéneo optimizado para operaciones vectorizadas, y funciones para álgebra lineal, transformadas de Fourier y generación de números aleatorios [37].

En este TFG, NumPy se utiliza para operaciones aritméticas sobre arrays (cálculo de raíces cuadradas para RMSE, operaciones con vectores de residuos) y como capa subyacente de Pandas y Scikit-learn.

4.2.2. Pandas

Pandas es la librería estándar para la manipulación y el análisis de datos tabulares en Python. Su estructura principal, el `DataFrame`, permite cargar, filtrar, transformar y agregar datos de forma eficiente y expresiva [38].

En este trabajo, Pandas se emplea para la carga del CSV (`pd.read_csv`), la limpieza de nombres de columnas, el tratamiento de valores faltantes (`dropna`), el filtrado por año, el agrupamiento (`groupby`) para el análisis temporal y la selección de subconjuntos de variables.

4.2.3. Matplotlib y Seaborn

Matplotlib es la librería de visualización más utilizada en Python, que permite crear gráficos estáticos de alta calidad [39]. Seaborn es una capa de alto nivel sobre Matplotlib orientada a la visualización estadística, que simplifica la creación de histogramas con estimación de densidad (KDE), boxplots, mapas de calor de correlación y gráficos de dispersión [40].

Todas las figuras de este TFG se han generado con estas dos librerías, utilizando Seaborn para la mayoría de gráficos estadísticos y Matplotlib para el ajuste fino de ejes, títulos y anotaciones.

4.2.4. Scikit-learn

Scikit-learn es la librería de referencia para *machine learning* en Python. Proporciona implementaciones eficientes de algoritmos de clasificación, regresión, clustering y reducción de dimensionalidad, junto con herramientas para preprocesamiento, selección de modelos y evaluación [19].

En este TFG se utilizan los siguientes módulos de Scikit-learn:

- `LinearRegression`: regresión lineal por mínimos cuadrados ordinarios.
- `Ridge`: regresión lineal con regularización L2.
- `RandomForestRegressor`: ensemble de árboles de decisión.
- `StandardScaler`: estandarización de variables (media 0, desviación estándar 1).
- `GridSearchCV`: búsqueda exhaustiva de hiperparámetros con validación cruzada.
- `mean_squared_error`, `r2_score`, `mean_absolute_error`: métricas de evaluación.

4.2.5. Statsmodels

Statsmodels complementa a Scikit-learn proporcionando tests estadísticos clásicos. En este trabajo se emplean el test de Breusch-Pagan para heterocedasticidad y el test de Durbin-Watson para autocorrelación de residuos [41].

La Figura 4.2 recoge los logotipos de las seis librerías utilizadas en este trabajo.



Figura 4.2: Logotipos de las librerías de Python utilizadas en este TFG: NumPy [37], Pandas [38], Matplotlib [39], Seaborn [40], Scikit-learn [19] y Statsmodels [41].

4.3. Conceptos de aprendizaje automático

4.3.1. Aprendizaje supervisado

El aprendizaje supervisado es el paradigma de *machine learning* en el que se dispone de un conjunto de datos etiquetados, es decir, pares (x_i, y_i) donde x_i es un vector de características y y_i es la variable objetivo. El algoritmo aprende una función $f : X \rightarrow Y$ que minimiza una función de pérdida sobre los datos de entrenamiento y se generaliza a datos no vistos [42].

En este TFG, los dos modelos desarrollados son problemas de regresión supervisada: a partir de variables socioeconómicas y energéticas (x), se predice un valor numérico continuo (y): emisiones de CO₂ o consumo per cápita.

4.3.2. División del dataset: train/test temporal

Una práctica habitual en *machine learning* es dividir el dataset en un conjunto de entrenamiento (para ajustar el modelo) y uno de test (para evaluar su capacidad de generalización). En este trabajo se emplea una **división temporal**: los datos de 2000–2015 se usan para entrenamiento y los de 2016–2019 para test. Esta decisión tiene una justificación doble: evita la fuga de información temporal (*data leakage*)¹ [43] y simula un escenario realista en el que se entrenan modelos con datos históricos para predecir el futuro.

¹Se denomina *data leakage* (fuga de datos) a la situación en la que información del conjunto de test se filtra inadvertidamente al proceso de entrenamiento, produciendo resultados engañosamente optimistas que no se reproducen con datos realmente nuevos.

4.3.3. Estandarización de variables

La estandarización consiste en transformar cada variable para que tenga media 0 y desviación estándar 1, como se indica en la Ecuación 4.1.

$$z_i = \frac{x_i - \bar{x}}{s_x} \quad (4.1)$$

donde $\bar{x}$ es la media y s_x la desviación estándar del conjunto de entrenamiento. Esta transformación es esencial para algoritmos sensibles a la escala (especialmente la regresión de Ridge) y facilita la interpretación de los coeficientes. En este TFG se aplica de forma consistente utilizando `StandardScaler` de Scikit-learn, ajustando la transformación solo con datos de entrenamiento y aplicándola tanto a train como a test para evitar *data leakage* [43].

4.4. Algoritmos de regresión utilizados

4.4.1. Regresión lineal múltiple

La regresión lineal múltiple modela la relación entre una variable dependiente y y un conjunto de p variables independientes $x_1, x_2, \dots, x_p$ mediante la expresión de la Ecuación 4.2.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (4.2)$$

Los coeficientes β_j se estiman minimizando la suma de cuadrados de los residuos (método de mínimos cuadrados ordinarios, OLS) [44]. La regresión lineal asume linealidad, independencia de los errores, homocedasticidad² y normalidad de los residuos [44, 45].

4.4.2. Regresión Ridge

Ridge es una extensión de la regresión lineal que añade un término de penalización L2 sobre los coeficientes, como se expresa en la Ecuación 4.3.

²La *homocedasticidad* (del griego *homo*, igual, y *skedasis*, dispersión) es la propiedad estadística por la cual la varianza de los errores de un modelo es constante para todos los valores de las variables predictoras. Su opuesto, la *heterocedasticidad*, implica que la dispersión de los errores varía según el rango de valores predichos.

$$\hat{\beta}_{Ridge} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \alpha \sum_{j=1}^p \beta_j^2 \right\} \quad (4.3)$$

El hiperparámetro α controla la intensidad de la regularización: valores altos de α fuerzan coeficientes más pequeños, lo que reduce la varianza del modelo — es decir, hace que las predicciones sean más estables ante cambios en los datos de entrenamiento — a costa de un mayor sesgo, esto es, una mayor simplificación de la realidad. La regularización busca precisamente un equilibrio entre ambos extremos: un modelo demasiado flexible se ajusta en exceso a los datos de entrenamiento (*overfitting*), mientras que uno demasiado rígido simplifica en exceso (*underfitting*). El valor óptimo de α se selecciona mediante validación cruzada (*GridSearchCV*), una técnica que divide los datos de entrenamiento en k subconjuntos, entrena el modelo k veces dejando cada vez uno fuera para evaluar, y promedia los resultados para obtener una estimación robusta del rendimiento [42].

4.4.3. Random Forest

Random Forest es un método de *ensemble* — es decir, combina las predicciones de múltiples modelos individuales para obtener un resultado más preciso que el de cualquier modelo por separado — basado en la técnica de *bagging* (*bootstrap aggregating*), que consiste en entrenar cada modelo sobre una muestra aleatoria con reemplazo del dataset original. En concreto, Random Forest construye múltiples árboles de decisión, cada uno entrenado sobre un subconjunto diferente de las observaciones y de las variables [46]. La predicción final se obtiene como el promedio de las predicciones individuales, según la Ecuación 4.4.

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B f_b(x) \quad (4.4)$$

donde B es el número de árboles y f_b es la función de predicción del árbol b -ésimo. Sus principales ventajas son: capacidad para capturar relaciones no lineales, robustez frente al *overfitting* y la posibilidad de medir la importancia de las variables mediante la disminución media de la impureza³ (*feature importance*).

³La **impureza** mide cuánta variabilidad queda sin explicar en los datos tras una partición del árbol de decisión. Cada vez que un árbol divide los datos usando una variable, la impureza se reduce. La *feature importance* de una variable se calcula como la reducción media de impureza que produce esa variable en todos los árboles del bosque: cuanto más impureza reduce, más importante es para la predicción.

4.5. Métricas de evaluación

4.5.1. Coeficiente de determinación (R^2)

El coeficiente de determinación se calcula según la Ecuación 4.5.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4.5)$$

Representa la proporción de la varianza de la variable dependiente explicada por el modelo. Un $R^2 = 1$ indica un ajuste perfecto; $R^2 = 0$ indica que el modelo no explica nada más que la media [45].

4.5.2. Error absoluto medio (MAE)

El error absoluto medio se define como se muestra en la Ecuación 4.6.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.6)$$

4.5.3. Raíz del error cuadrático medio (RMSE)

La raíz del error cuadrático medio se calcula mediante la Ecuación 4.7.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.7)$$

El RMSE penaliza más los errores grandes que el MAE, lo que lo hace especialmente útil cuando los outliers son relevantes [45].

4.5.4. Diagnóstico de residuos

Las métricas anteriores (R^2 , MAE, RMSE) miden la precisión global del modelo, pero no informan sobre si el modelo cumple las asunciones estadísticas necesarias para que sus estimaciones sean fiables. Para ello se analizan los **residuos** ($e_i = y_i - \hat{y}_i$), es decir, la diferencia entre lo que el modelo predice y lo que ocurrió realmente. Si el modelo es adecuado, los residuos deberían comportarse como ruido aleatorio: sin patrones, sin tendencias y con una dispersión uniforme [44].

En este TFG se aplican dos tests formales sobre los residuos:

Test de Breusch-Pagan (heterocedasticidad)

La regresión lineal asume que los errores tienen varianza constante para todos los niveles de la variable predicha (homocedasticidad). Cuando esto no se cumple — por ejemplo, si los errores son pequeños para países con emisiones bajas pero grandes para países con emisiones altas — se habla de **heterocedasticidad**.

El test de Breusch-Pagan [47] permite verificar formalmente si esta asunción se cumple. Como todo test de hipótesis, plantea dos hipótesis contrapuestas:

- H_0 (**hipótesis nula**): la varianza de los errores es constante para todos los valores predichos (homocedasticidad). Es la situación deseable, la que se asume como punto de partida.
- H_1 (**hipótesis alternativa**): la varianza de los errores depende de los valores predichos (heterocedasticidad). Es la situación problemática que el test intenta detectar.

El procedimiento consiste en tomar los residuos al cuadrado del modelo (e_i^2) y realizar una regresión auxiliar de estos residuos sobre las variables predictoras. Si los predictores explican una proporción significativa de la variabilidad de los residuos al cuadrado, quiere decir que la dispersión de los errores no es aleatoria sino que depende de las variables del modelo, lo que confirmaría heterocedasticidad. El resultado del test se resume en el estadístico LM (*Lagrange Multiplier*, multiplicador de Lagrange), que se calcula como el producto del número de observaciones por el coeficiente de determinación de la regresión auxiliar, como se indica en la Ecuación 4.8.

$$LM = n \times R_{\text{aux}}^2 \quad (4.8)$$

donde n es el número de observaciones y R_{aux}^2 es el R^2 de la regresión de los residuos al cuadrado sobre los predictores. Este estadístico sigue una distribución χ^2 con p grados de libertad (siendo p el número de variables predictoras): si el p -valor asociado es inferior a 0,05, se rechaza H_0 y se concluye que existe heterocedasticidad. Un valor alto de LM indica que los predictores explican bien la variabilidad de los residuos, es decir, que la dispersión de los errores no es constante. En la práctica, esto no invalida el modelo predictivo, pero indica que las predicciones son menos fiables en ciertos rangos — en el caso de este trabajo, para las grandes economías emisoras.

Test de Durbin-Watson (autocorrelación)

En datos con estructura temporal como los de este TFG, es habitual que los residuos de un año estén correlacionados con los del año anterior (autocorrelación). El test de Durbin-Watson [48] detecta esta situación mediante un estadístico d que se calcula como el cociente entre la suma de las diferencias al cuadrado de residuos consecutivos y la suma total de los residuos al cuadrado, como se muestra en la Ecuación 4.9.

$$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \quad (4.9)$$

El estadístico d varía entre 0 y 4, y su interpretación es la siguiente:

- $d \approx 2$: no hay autocorrelación (situación ideal). Las diferencias entre residuos consecutivos son comparables a los propios residuos, lo que indica que cada residuo es independiente del anterior.
- $d < 1,5$: indica autocorrelación positiva (los residuos tienden a mantener el mismo signo de un año a otro). En este caso, el numerador es pequeño porque los residuos consecutivos se parecen entre sí.
- $d > 2,5$: indica autocorrelación negativa (los residuos tienden a alternar de signo).

La presencia de autocorrelación es esperable cuando se trabaja con datos de panel (múltiples países observados a lo largo del tiempo), ya que la situación energética de un país en un año dado está fuertemente condicionada por la del año anterior [45].

Capítulo 5

Datos y fuentes de información

5.1. Dataset principal: Global Data on Sustainable Energy

El dataset principal utilizado en este TFG es el *Global Data on Sustainable Energy*, disponible públicamente en la plataforma Kaggle [49]. Contiene datos de 176 países para el periodo 2000–2020, con 21 variables que cubren indicadores de energía sostenible y otros factores socioeconómicos relevantes: acceso a la electricidad, cuota de energías renovables, emisiones de carbono, intensidad energética, flujos financieros hacia países en desarrollo y crecimiento económico, entre otros.

El dataset fue construido a partir de tres fuentes principales: el Banco Mundial (*World Bank*), la Agencia Internacional de la Energía (IEA) y Our World in Data, siendo esta última la fuente mayoritaria de las variables a través de su recopilación sobre energía limpia y asequible vinculada al ODS 7. Según la descripción proporcionada en Kaggle por el autor del dataset, estas tres instituciones proporcionan los indicadores de acceso energético, generación eléctrica, emisiones, intensidad energética y variables socioeconómicas que componen las 21 columnas del archivo. El dataset se distribuye bajo licencia abierta y ha sido ampliamente utilizado en análisis y competiciones dentro de la comunidad de Kaggle.

La combinación de variables energéticas, económicas y geográficas en un mismo panel temporal hace de este dataset una herramienta especialmente adecuada para el tipo de análisis que se desarrolla en este trabajo: permite tanto el estudio exploratorio de las relaciones entre desarrollo económico y consumo energético, como la construcción de modelos predictivos de regresión supervisada. La Tabla 5.1 recoge las variables disponibles.

5.1.1. Variables del dataset

Tabla 5.1: Variables del dataset principal y su descripción.

Variable	Descripción	Unidad
Entity	Nombre del país	—
Year	Año de la observación	—
Access to electricity	Porcentaje de población con acceso a electricidad	%
Access to clean fuels for cooking	Acceso a combustibles limpios para cocinar	%
Renewable energy share	Cuota de renovables en el consumo final	%
Electricity from fossil fuels	Generación eléctrica con combustibles fósiles	TWh
Electricity from nuclear	Generación eléctrica nuclear	TWh
Electricity from renewables	Generación eléctrica renovable	TWh
Low-carbon electricity	Porcentaje de electricidad baja en carbono	%
Primary energy per capita	Consumo energético per cápita	kWh/persona
Energy intensity	Intensidad energética del PIB	MJ/\$
CO ₂ emissions	Emisiones de CO ₂ por país	kt
Renewables equiv. primary energy	Energía primaria renovable equivalente	%
gdp_per_capita	PIB per cápita	USD
gdp_growth	Tasa de crecimiento del PIB	%
Financial flows to developing	Flujos financieros a países en desarrollo	USD
Renewable energy capacity per capita	Capacidad renovable instalada per cápita	W/persona
Density	Densidad de población	hab/km ²
Land area	Superficie terrestre	km ²
Latitude / Longitude	Coordenadas geográficas	grados

5.1.2. Decisiones de limpieza

1. **Estandarización de nombres de columnas:** eliminación de saltos de línea y espacios en los nombres.
2. **Exclusión del año 2020:** el análisis preliminar reveló que 2020 presentaba un porcentaje muy elevado de valores faltantes debido a los diferentes calendarios de publicación de las fuentes estadísticas. Se optó por excluir este año para mantener la integridad del panel.
3. **Tratamiento de valores faltantes:** eliminación de filas con valores nulos en las variables utilizadas en el modelado.

5.2. Dataset secundario: Our World in Data

El dataset secundario utilizado para la validación externa es el archivo `owid-energy-data.csv`, mantenido por el equipo de *Our World in Data* (OWID) y disponible en su repositorio oficial de GitHub [50]. Este dataset se descarga desde la página de energía de OWID [15], que ofrece visualizaciones interactivas y acceso directo a los datos subyacentes.

A diferencia del dataset de Kaggle, que es una recopilación estática publicada en un momento concreto, el dataset de OWID se actualiza periódicamente e integra datos de múltiples fuentes primarias: el *Statistical Review of World Energy* (anteriormente publicado por BP, actualmente por el Energy Institute), Ember para datos de generación eléctrica, el Maddison Project para series históricas de PIB, y diversas bases de datos de Naciones Unidas y el Banco Mundial.

Esta diversidad de fuentes hace del dataset de OWID un candidato natural para la validación externa, pero al mismo tiempo introduce diferencias en las definiciones y escalas de medida de algunas variables, como se analiza en detalle en el Capítulo 8.

5.3. Otras fuentes de datos consultadas

- **ESIOS (Red Eléctrica de España):** datos en tiempo real e históricos de demanda, generación por tecnología y precios del mercado eléctrico español.
- **datos.gob.es:** repositorio del Gobierno de España con históricos de consumos mensuales.
- **INE:** Encuesta de consumos energéticos por sectores.
- **IDAE:** Balances energéticos y estadísticas de eficiencia.
- **Enerdata:** Estadísticas energéticas mundiales actualizadas.
- **IEA:** Datasets globales de demanda eléctrica y patrones de consumo sectorial.
- **Statista:** Datos procesados sobre consumo de energía primaria por país.

Capítulo 6

Análisis exploratorio de datos

6.1. Inspección inicial del dataset

Tras cargar el dataset con `pd.read_csv()`, la inspección inicial revela 3.649 observaciones y 21 variables. La Tabla 6.1 resume la estructura completa del dataset, indicando para cada variable su nombre original, el tipo de dato y el número de valores disponibles (no nulos). Esta información, obtenida mediante `df.info()`, permite identificar de forma inmediata qué variables presentan valores faltantes y en qué proporción.

Tabla 6.1: Estructura del dataset: variables, tipos de datos y completitud.

#	Variable	Categoría	Tipo	No nulos
0	Entity	Identificación	object	3.649
1	Year	Identificación	int64	3.649
2	Access to electricity (%)	Acceso	float64	3.639
3	Access to clean fuels for cooking	Acceso	float64	3.480
4	Renew.-elec.-generating-capacity-per-capita	Renovables	float64	2.718
5	Financial flows to developing countries (US\$)	Económica	float64	1.560
6	Renewable energy share (%)	Renovables	float64	3.455
7	Electricity from fossil fuels (TWh)	Generación	float64	3.628
8	Electricity from nuclear (TWh)	Generación	float64	3.523
9	Electricity from renewables (TWh)	Generación	float64	3.628
10	Low-carbon electricity (%)	Generación	float64	3.607
11	Primary energy consumption per capita (kWh/p)	Consumo	float64	3.649
12	Energy intensity (MJ/\$2017 PPP GDP)	Eficiencia	float64	3.442
13	Value_co2_emissions_kt_by_country	Emisiones	float64	3.221
14	Renewables (% equivalent primary energy)	Renovables	float64	1.512
15	gdp_growth	Económica	float64	3.332
16	gdp_per_capita	Económica	float64	3.367
17	Density (P/Km ²)	Geográfica	object	3.648
18	Land Area (Km ²)	Geográfica	float64	3.648
19	Latitude	Geográfica	float64	3.648
20	Longitude	Geográfica	float64	3.648

Se observa que la mayoría de las variables tienen una completitud elevada (superior al 90 %), con dos excepciones notables: Financial flows to developing

countries (1.560 valores, 42,7%) y Renewables (% equivalent primary energy) (1.512 valores, 41,4 %), que serán eliminadas en la fase de limpieza por superar el umbral del 40 % de valores faltantes. Por otra parte, la variable Density se almacena como texto (object) debido al uso de comas como separador de miles en el archivo original, por lo que requerirá una conversión a formato numérico.

6.2. Análisis univariado

El análisis univariado permite estudiar la distribución de cada variable de forma independiente antes de analizar sus relaciones mutuas.

6.2.1. Distribución de emisiones de CO₂




Figura 6.1: Distribución de emisiones de CO₂ (kt).

La distribución (Figura 6.1) presenta una asimetría positiva muy pronunciada ($\text{skew} \approx 9,34$), lo que indica que la gran mayoría de países tienen emisiones relativamente bajas, mientras que un grupo reducido de economías de gran escala (China, Estados Unidos, India, Rusia) concentra la mayor parte de las emisiones globales.

6.2.2. Distribución del consumo energético per cápita




Figura 6.2: Distribución del consumo energético per cápita (kWh/persona).

El consumo per cápita (Figura 6.2) también presenta asimetría positiva ($\text{skew} \approx 2,58$), aunque menos extrema que en el caso anterior.

Mientras la mayoría de los países se concentran en niveles relativamente bajos o moderados de consumo energético per cápita, existe un número reducido de economías que presenta valores mucho más elevados, generando de nuevo una cola hacia la derecha.

Este comportamiento refleja las importantes desigualdades en el desarrollo energético a nivel global. Por un lado, se encuentran países del África subsahariana con consumos mínimos, asociados a un acceso limitado a la energía y a un menor grado de industrialización. Por otro, destacan economías como Islandia, Catar o Noruega, que presentan consumos per cápita excepcionalmente altos, debido tanto a su elevado nivel de renta como a factores estructurales: la disponibilidad de recursos energéticos, la presencia de condiciones climáticas extremas o bien la especialización en industrias intensivas en energía.

6.2.3. Distribución del PIB per cápita




Figura 6.3: Distribución del PIB per cápita (USD).

Sigue un patrón similar (Figura 6.3), con asimetría positiva ($\text{skew} \approx 2,36$), coherente con la desigual distribución de la riqueza a nivel global. La mayoría de los países se concentra en niveles bajos o medios de PIB per cápita, mientras que un grupo reducido de economías desarrolladas presenta valores significativamente más elevados.

6.2.4. Conclusión del análisis univariado

Las tres variables principales presentan distribuciones con cola derecha, un patrón habitual en datos macroeconómicos que refleja la concentración de recursos y actividad económica en un número limitado de países. Esta asimetría evidencia la heterogeneidad existente entre economías y la presencia de valores extremos.

6.3. Detección de outliers

6.3.1. Boxplot de emisiones de CO₂




Figura 6.4: Boxplot de emisiones de CO₂.

El boxplot (Figura 6.4) confirma la presencia de outliers según el criterio del IQR, correspondientes a las grandes economías emisoras. Estos valores **no se eliminan**, ya que representan datos reales de países cuya escala económica y demográfica explica sus niveles de emisión.

6.3.2. Boxplot de consumo energético per cápita




Figura 6.5: Boxplot de consumo energético per cápita.

Los outliers (Figura 6.5) corresponden a economías con características energéticas particulares: climas extremos, industrias intensivas o poblaciones pequeñas con alta producción de hidrocarburos.

6.4. Análisis bivariado y multivariado

6.4.1. Análisis de correlaciones

Se calcula la matriz de correlaciones de Pearson para todas las variables numéricas (Figura 6.6).




Figura 6.6: Mapa de calor de correlaciones.

Correlación con emisiones de CO₂

Las emisiones muestran una correlación $r \approx 0,99$ con la generación eléctrica fósil, lo que tiene sentido físico pero representa un problema de predicción casi tautológica. Las correlaciones con las demás variables (generación nuclear $r \approx 0,76$, generación renovable $r \approx 0,56$) son relevantes pero de menor magnitud.

Correlación con consumo energético per cápita

El consumo per cápita se correlaciona más fuertemente con el PIB per cápita ($r \approx 0,68$), el acceso a combustibles limpios ($r \approx 0,56$) y el acceso a electricidad ($r \approx 0,46$).

6.4.2. Detección de redundancia

Se identifican pares de variables con correlación absoluta superior a 0,9. Solo se detecta la relación ya conocida entre CO₂ y generación fósil entre las variables explicativas.

6.4.3. Selección inicial de variables por correlaciones

Antes de calcular el VIF, se realiza un primer filtrado descartando las variables que presentan correlaciones bajas con ambos objetivos y para las que no existe una justificación teórica clara:

- Latitude y Longitude: correlaciones muy bajas con CO₂ ($r \approx 0,12$ y $r \approx 0,04$) y con el consumo per cápita ($r \approx 0,34$ y $r \approx 0,04$). La latitud guarda cierta relación con el consumo a través del clima (países más fríos necesitan más calefacción), pero el PIB per cápita ya captura gran parte de esa variabilidad. Longitud carece de interpretación causal. Se descartan ambas.
- Renewable electricity generating capacity per capita: correlación casi nula con ambas variables objetivo ($r \approx 0,04$ y $r \approx -0,01$). Mide la capacidad instalada por habitante, no la generación real ni el consumo.
- Density: correlación prácticamente nula con ambos objetivos ($r \approx 0,01$). No aporta información adicional a la del PIB per cápita y la superficie.
- Access to clean fuels for cooking: presenta correlación con el consumo per cápita ($r \approx 0,56$), pero mide un concepto similar a Access to electricity ($r \approx 0,46$), ya incluida en el modelo de energía. Incluir ambas introduciría redundancia sin mejorar la capacidad explicativa.

6.4.4. Selección diferenciada de variables por modelo

Tras descartar las variables con correlaciones bajas o redundantes, las variables restantes se asignan a cada modelo en función de su relevancia para la variable objetivo correspondiente.

Variables para el Modelo A (emisiones de CO₂)

Las emisiones de CO₂ son una magnitud absoluta (kt totales por país), por lo que las variables que más correlacionan con ellas son las de generación eléctrica, que capturan el tamaño y la composición del sistema energético: la generación fósil ($r \approx 0,99$), la renovable ($r \approx 0,86$) y la nuclear ($r \approx 0,60$). A estas se añaden la cuota renovable ($r \approx -0,13$) y el porcentaje de electricidad baja en carbono ($r \approx -0,05$), que aportan información complementaria sobre la estructura del mix energético; la intensidad energética ($r \approx 0,04$), relevante por su papel dentro de la identidad de Kaya; y Year ($r \approx 0,02$), que captura la tendencia temporal global.

En cambio, se excluyen las variables económicas (gdp_per_capita, $r \approx 0,10$; gdp_growth, $r \approx 0,03$) y de acceso (Access to electricity, $r \approx 0,13$), cuyas correlaciones con las emisiones totales son muy bajas. Esto se explica porque un país pequeño pero rico puede tener un PIB per cápita alto y emisiones totales bajas, y viceversa: las emisiones totales dependen del tamaño del sistema energético, no del nivel de renta. Land Area ($r \approx 0,65$) se excluye por ser un proxy del tamaño del país que ya está capturado por las variables de generación.

La correlación casi perfecta entre generación fósil y CO₂ ($r \approx 0,99$) invita a explorar un modelo con y otro sin dicha variable entre los predictores, para evaluar si el modelo aprende relaciones estructurales genuinas o simplemente reproduce una relación física casi directa.

Variables para el Modelo B (consumo energético per cápita)

Al tratarse de una magnitud per cápita, las variables económicas y de acceso cobran protagonismo. El PIB per cápita es el predictor con mayor correlación ($r \approx 0,68$), seguido del acceso a electricidad ($r \approx 0,46$). La cuota renovable presenta una correlación negativa notable ($r \approx -0,44$): los países con mayor proporción de renovables tienden a tener consumos per cápita más moderados. Se incluye gdp_growth ($r \approx -0,04$) porque, aunque su correlación individual es baja, aporta información sobre la dinámica de crecimiento que complementa al PIB per cápita en nivel.

Las variables de generación eléctrica se mantienen ($r \approx 0,11-0,18$) porque capturan la estructura del sistema energético. La intensidad energética ($r \approx 0,13$) refleja la eficiencia del sistema productivo, y Land Area ($r \approx 0,12$) se incluye como indicador de escala territorial, relevante porque los países extensos tienden a tener mayores necesidades de transporte y climatización. La variable Year también se incluye inicialmente.

6.4.5. Verificación de multicolinealidad (VIF)

Una vez seleccionadas las variables candidatas para cada modelo, se verifica que no exista multicolinealidad excesiva entre ellas. El Factor de Inflación de la Varianza (VIF) cuantifica esta propiedad mediante la Ecuación 6.1.

$$VIF_j = \frac{1}{1 - R_j^2} \quad (6.1)$$

donde R_j^2 es el coeficiente de determinación de la regresión de la variable j sobre el resto de predictores. Valores por debajo de 5 se consideran aceptables, entre 5 y 10 indican colinealidad moderada, y por encima de 10 la variable es altamente redundante [44].

Es importante señalar que la multicolinealidad no afecta a la capacidad predictiva del modelo (el R^2 no cambia), pero sí dificulta la interpretación de los coeficientes individuales: si dos predictores están muy correlacionados, el modelo no puede separar con claridad el efecto de cada uno. Para un trabajo con objetivo predictivo no es un problema tan grave, pero igualmente es bueno verificarlo.

VIF del Modelo de CO₂

Tabla 6.2: Valores VIF – Modelo de emisiones de CO₂.

Variable	VIF
Electricity from fossil fuels (TWh)	5,31
Year	4,70
Electricity from renewables (TWh)	4,04
Energy intensity level of primary energy (MJ/\$)	3,55
Low-carbon electricity (% electricity)	3,25
Renewable energy share (%)	3,21
Electricity from nuclear (TWh)	1,94

Todos los VIF están por debajo de 10 (Tabla 6.2). La generación fósil tiene el VIF más alto ($\approx 5,31$), pero en un nivel aceptable. El VIF de Year ($\approx 4,7$) también es aceptable, por lo que se mantiene como predictor en este modelo.

VIF del Modelo de consumo per cápita

En la primera iteración, la variable Year presenta un VIF ≈ 40 , indicando una colinealidad severa con el PIB per cápita (ambas crecen en el tiempo). Tras excluir Year, todos los VIF bajan a niveles aceptables (Tabla 6.3).

Tabla 6.3: Valores VIF – Modelo de energía per cápita (sin Year).

Variable	VIF
Electricity from fossil fuels (TWh)	5,41
Electricity from renewables (TWh)	5,26
Access to electricity (% of population)	3,94
Renewable energy share (%)	3,58
Low-carbon electricity (% electricity)	3,57
Energy intensity level of primary energy (MJ/\$)	3,34
Land Area (Km ²)	2,54
Electricity from nuclear (TWh)	2,11
gdp_per_capita	1,92
gdp_growth	1,57

6.4.6. Resumen del proceso de selección de variables

El proceso de selección se ha desarrollado en cinco pasos:

1. **Limpieza:** se eliminaron Financial flows to developing countries y Renewables (% equivalent primary energy) por superar el umbral del 40 % de valores faltantes.
2. **Descarte por correlación baja:** se excluyeron Latitude, Longitude, Renewable electricity generating capacity per capita, Density y Access to clean fuels for cooking por correlaciones bajas con ambos objetivos o por redundancia con predictores de mayor calidad ya incluidos.
3. **Asignación diferenciada por modelo:** las variables económicas y de acceso (gdp_per_capita, gdp_growth, Access to electricity, Land Area) se incluyen solo en el Modelo B, donde presentan correlaciones relevantes con el consumo per cápita, y se excluyen del Modelo A, donde sus correlaciones con las emisiones totales son muy bajas ($r < 0,13$).

4. **Verificación VIF:** se comprueba que las variables seleccionadas no presenten multicolinealidad excesiva. En el Modelo A todos los VIF son aceptables. En el Modelo B, Year presenta un $VIF \approx 40$ (colinealidad severa con gdp_per_capita), por lo que se excluye; tras su eliminación, todos los VIF bajan a niveles aceptables.

5. **Variables finales:**

- Modelo A (CO₂): Year, Electricity from fossil fuels*, Electricity from nuclear, Electricity from renewables, Renewable energy share, Low-carbon electricity, Energy intensity. (*Excluida en el modelo revisado.)
- Modelo B (energía per cápita): gdp_per_capita, gdp_growth, Electricity from fossil fuels, Electricity from nuclear, Electricity from renewables, Renewable energy share, Low-carbon electricity, Energy intensity, Access to electricity, Land Area.

6.4.7. Alternativa descartada: Análisis de Componentes Principales (PCA)

Como alternativa al proceso manual de selección, podría haberse aplicado el Análisis de Componentes Principales (PCA) para reducir la dimensionalidad del dataset. Sin embargo, se ha optado por no utilizarlo por dos razones.

En primer lugar, el número de variables es reducido (21 columnas originales, de las cuales menos de la mitad entran en cada modelo), por lo que la reducción de dimensionalidad no resulta necesaria. En segundo lugar, y más importante, PCA transforma las variables originales en combinaciones lineales abstractas (componentes principales) que pierden su significado físico y económico. Por ejemplo, en un modelo donde una componente principal mezclas el PIB per cápita con la generación nuclear y la cuota renovable, ya no sería posible afirmar que «el PIB per cápita es el factor más determinante del consumo energético», que es precisamente uno de los hallazgos relevantes de este trabajo.

Dado que uno de los objetivos del TFG es identificar los determinantes estructurales de las emisiones y el consumo energético, se ha preferido mantener las variables originales con su interpretación intacta [45].

6.5. Análisis temporal global

El análisis temporal permite contextualizar los resultados del modelado predictivo dentro de la evolución histórica del sistema energético global. Se examina el periodo 2000–2019 y se utiliza el año 2015 (firma del Acuerdo de París) como referencia para evaluar posibles cambios de tendencia.

6.5.1. Evolución de las emisiones globales de CO₂




Figura 6.7: Emisiones globales de CO₂ (2000–2019).

Las emisiones globales de CO₂ (Figura 6.7) muestran una tendencia creciente sostenida a lo largo de todo el periodo analizado. Se observa una desaceleración momentánea alrededor de 2009 (coincidiendo con la crisis financiera global) seguida de una recuperación y un crecimiento continuado. La línea vertical en 2015 marca la firma del Acuerdo de París, pero no se aprecia una ruptura de tendencia posterior: las emisiones siguieron creciendo entre 2015 y 2019, si bien a un ritmo algo menor.

Cabe señalar que sería de interés disponer de datos más recientes para analizar el impacto de eventos posteriores, como la pandemia de la COVID-19 —que provocó una caída puntual de la actividad económica y de las emisiones— y las tensiones

geopolíticas actuales, entre ellas la guerra en Ucrania o la inestabilidad en el estrecho de Ormuz, que han afectado a los mercados energéticos y podrían haber modificado la evolución reciente de las emisiones.

6.5.2. Evolución de la cuota de energías renovables




Figura 6.8: Proporción media de energías renovables en el consumo final.

La cuota renovable media global (Figura 6.8) muestra una tendencia ligeramente decreciente durante la primera parte del periodo analizado, con una estabilización a partir de aproximadamente 2015. Este patrón puede explicarse por el rápido crecimiento del consumo energético total en economías emergentes (especialmente basado en combustibles fósiles), que hizo que la proporción renovable disminuyera en términos relativos aunque la generación renovable creciera en términos absolutos. La estabilización posterior puede estar relacionada con un mayor despliegue de infraestructuras renovables (parques eólicos, plantas fotovoltaicas) impulsado por los compromisos políticos internacionales, si bien los efectos de estos ciclos de inversión y construcción suelen tardar varios años en traducirse.

Es importante destacar que esta variable representa una media global que puede ocultar tendencias regionales muy distintas: países como España, Alemania o

Dinamarca han experimentado incrementos notables en su cuota renovable durante este periodo.

6.5.3. Comparación antes y después de 2015

Para cuantificar si existe un cambio estructural asociado al Acuerdo de París, se comparan las medias de emisiones globales y cuota renovable entre los periodos 2000–2014 y 2015–2019. Los resultados no muestran diferencias estadísticamente significativas en ninguna de las dos variables.

Este resultado no debe interpretarse como un fracaso del Acuerdo de París, sino como una consecuencia de su propia naturaleza: el acuerdo establece compromisos a medio y largo plazo (neutralidad de carbono para 2050) y funciona en ciclos de cinco años de ambición creciente. Los cambios reales en la infraestructura energética global — reconversión de centrales, despliegue de renovables a gran escala, electrificación del transporte — requieren décadas para materializarse plenamente.

El periodo de observación disponible (apenas cuatro años post-acuerdo) es demasiado corto para detectar un cambio de tendencia a escala global, aunque sí se observan avances significativos a nivel regional, como los descritos en la Sección [2.1.1](#) para el caso español.

Capítulo 7

Modelado predictivo

7.1. Modelo A: Predicción de emisiones de CO₂

7.1.1. Planteamiento y selección de variables

El primer modelo tiene como objetivo predecir las emisiones totales de CO₂ por país y año (en kt). Se prueban tres algoritmos: regresión lineal (como base interpretable), Ridge (para evaluar si la regularización mejora el resultado) y Random Forest (como contraste no lineal). Se aplica la división temporal: 2000–2015 para entrenamiento y 2016–2019 para test.

Las variables seleccionadas, conforme al análisis detallado en la Sección 6.4.4, son 7 predictores centrados en la generación eléctrica y la estructura del sistema energético:

- Year
- Electricity from fossil fuels (TWh)*
- Electricity from nuclear (TWh)
- Electricity from renewables (TWh)
- Renewable energy share (%)
- Low-carbon electricity (%)
- Energy intensity (MJ/\$)

*Excluida en el modelo revisado (Sección 7.1.6).

7.1.2. Resultados con generación fósil

Tabla 7.1: Comparación de modelos – Modelo A con generación fósil.

Modelo	R ²	MAE (kt)	RMSE (kt)
Regresión Lineal	0,9748	49.746	145.583
Ridge ($\alpha = 0,01$)	0,9748	49.746	145.583
Random Forest (max_depth = 15)	0,8970	47.011	294.371

Los tres modelos (Tabla 7.1) confirman la misma historia: la relación entre generación fósil y emisiones de CO₂ es esencialmente lineal. Regresión lineal y Ridge dan resultados idénticos — el α óptimo de 0,01 es prácticamente cero, lo que significa que la regularización no es necesaria porque los coeficientes ya son estables. El Random Forest obtiene un R^2 inferior (0,897 vs. 0,975), lo que indica que un modelo no lineal no aporta ventaja cuando la relación subyacente es lineal. Su RMSE considerablemente más alto refleja que comete errores más grandes en los países con emisiones extremas.

La importancia de variables del Random Forest confirma que más del 94 % del poder predictivo recae sobre la generación fósil. Todo apunta en la misma dirección: incluir una variable con correlación $r \approx 0,99$ con el objetivo produce un modelo preciso pero tautológico, que no está aprendiendo ninguna estructura estadística interesante sino reproduciendo una relación física casi directa.

7.1.3. Interpretación de coeficientes - Regresión Lineal

Al estar estandarizadas las variables, los coeficientes de la regresión lineal son directamente comparables en magnitud relativa: cada uno indica cuánto cambian las emisiones predichas (en kt) cuando esa variable aumenta en una desviación típica, manteniendo el resto constante.

Tabla 7.2: Coeficientes de la regresión lineal del Modelo A con generación fósil (variables estandarizadas).

Variable	Coeficiente
Year	-8.563
Electricity from fossil fuels (TWh)	+704.080
Electricity from nuclear (TWh)	-59.331
Electricity from renewables (TWh)	+73.408
Renewable energy share (%)	-4.915
Low-carbon electricity (% electricity)	+7.892
Energy intensity (MJ/\$)	+8.998

La electricidad fósil tiene con diferencia el coeficiente más alto (Tabla 7.2, $\approx +704000$ kt por σ), lo que refleja la relación casi directa entre generación fósil y emisiones. La electricidad renovable tiene coeficiente positivo ($\approx +73000$ kt por σ), lo que refleja un efecto de escala: los países que generan más renovables son también los que tienen sistemas energéticos más grandes en general. La electricidad nuclear tiene coeficiente negativo (≈ -59000 kt por σ), coherente con su papel de sustitución de fuentes fósiles. La intensidad energética tiene coeficiente positivo ($\approx +9000$ kt por σ): una mayor ineficiencia energética de la economía implica más emisiones.

Es importante señalar que estos coeficientes son coeficientes parciales que miden el efecto de cada variable manteniendo el resto constante. En la práctica, con datos observacionales como los de este trabajo, deben interpretarse con cautela por dos razones. En primer lugar, pueden estar capturando efectos confundidos entre variables correlacionadas entre sí; por ejemplo, el coeficiente positivo de la generación renovable no significa que las renovables causen más emisiones, sino que refleja la correlación de escala (países con sistemas energéticos grandes tienen más de todo). En segundo lugar, la estandarización permite comparar magnitudes relativas, pero no establece relaciones causales: una correlación estadística no implica causalidad, y factores no incluidos en el modelo (políticas energéticas concretas, precios de los combustibles, innovación tecnológica) pueden estar mediando las relaciones observadas.

7.1.4. Análisis de residuos - Regresión Lineal




Figura 7.1: Residuos del modelo lineal de CO₂ (con generación fósil).

Los mayoría de los residuos (Figura 7.1) están centrados en cero, con algunos puntos más dispersos. Los tests formales de diagnóstico (descritos en la Sección 4.5.4) revelan:

- **Breusch-Pagan:** el estadístico LM (*Lagrange Multiplier*) resulta $LM = 496,2$ con $p < 0,001$, lo que rechaza la hipótesis de homocedasticidad. La varianza de los residuos aumenta con el nivel de emisiones predichas: los países con

mayores emisiones (China, EE.UU., India) generan errores más grandes, lo cual es esperable dado que son las economías estructuralmente más complejas.

- **Durbin-Watson:** $d = 0,53$, muy por debajo del valor ideal de 2, lo que confirma autocorrelación positiva. Los errores de un mismo país en años consecutivos se parecen entre sí, un patrón común en datos de panel.

Ambas limitaciones afectan a la inferencia estadística (p-valores e intervalos de confianza de los coeficientes serían poco fiables), pero no invalidan las métricas predictivas (R^2 , MAE, RMSE) ni las conclusiones del estudio, dado que el objetivo del trabajo es predictivo.

7.1.5. Decisión metodológica: exclusión de la generación fósil

Los resultados anteriores son consistentes: la generación fósil explica prácticamente todo en este modelo. Incluir una variable con correlación $r \approx 0,99$ con el objetivo hace que el modelo sea preciso, pero no está aprendiendo ninguna estructura interesante. Por ello se procede a construir un modelo revisado excluyendo *Electricity from fossil fuels (TWh)*, con el objetivo de identificar los factores estructurales genuinos de las emisiones.

7.1.6. Resultados del modelo revisado (sin generación fósil)

Tabla 7.3: Comparación de modelos – Modelo A sin generación fósil.

Modelo	R^2	MAE (kt)	RMSE (kt)
Regresión Lineal	0,8048	163.546	405.271
Ridge ($\alpha = 1000$)	0,9086	114.106	277.366
Random Forest (max_depth = 20)	0,8756	54.697	323.585

Al quitar la variable fósil (Tabla 7.3), el rendimiento baja como era de esperar, pero los resultados siguen siendo razonables, lo que confirma que el resto de variables sí aportan información genuina sobre las emisiones. Ridge con $\alpha = 1000$ es el mejor modelo en R^2 (0,91) y RMSE (277.366 kt). Que el α óptimo sea tan alto (frente al 0,01 del modelo anterior) tiene sentido: sin el predictor dominante, los coeficientes son menos estables y la regularización ejerce un efecto beneficioso más marcado.

La importancia de variables del Random Forest en este modelo revisado muestra que la generación renovable pasa a ser el predictor principal (64 %), seguida de la generación nuclear (17 %) y la proporción de electricidad baja en carbono (7,5 %). Esto

confirma que, una vez eliminada la relación tautológica con la generación fósil, la composición del mix eléctrico y la eficiencia energética son los factores estructurales que determinan las emisiones de CO₂.

7.2. Modelo B: Predicción del consumo energético per cápita

7.2.1. Planteamiento y selección de variables

El segundo modelo predice el consumo energético per cápita (kWh/habitante). A diferencia de las emisiones totales, esta variable depende de factores económicos y de acceso que interactúan de formas no necesariamente lineales — por ejemplo, la relación entre PIB per cápita y consumo energético presenta saturación a rentas altas, análoga a la curva de Kuznets ambiental (Sección 2.4).

Las variables seleccionadas, conforme al análisis detallado en la Sección 6.4.4, son 10 predictores que combinan variables económicas, de acceso, de generación y de eficiencia:

- gdp_per_capita
- gdp_growth
- Electricity from fossil fuels (TWh)
- Electricity from nuclear (TWh)
- Electricity from renewables (TWh)
- Renewable energy share (%)
- Low-carbon electricity (%)
- Energy intensity (MJ/\$)
- Access to electricity (%)
- Land Area (Km²)

7.2.2. Regresión lineal

La regresión lineal explica el 63,5 % de la variabilidad del consumo per cápita ($R^2 = 0,635$), un resultado razonable para un fenómeno tan complejo pero claramente inferior al modelo de CO₂. Los coeficientes más relevantes son el PIB per cápita ($\approx +21669$ kWh por σ), que confirma el nivel de desarrollo económico como principal determinante; la intensidad energética ($\approx +10863$ kWh por σ), donde mayor ineficiencia del sistema productivo se traduce en más consumo; y el acceso a

electricidad ($\approx +7242$ kWh por σ), que refleja que los países con mayor cobertura eléctrica consumen más. La cuota renovable tiene coeficiente negativo (≈ -3661 kWh por σ): los países con mayor proporción de renovables tienden a tener consumos per cápita más moderados.

7.2.3. Ridge

Ridge con $\alpha = 100$ no mejora al modelo lineal ($R^2 = 0,631$). El α óptimo es más alto que en el Modelo A (donde era 0,01), lo que indica cierta inestabilidad en los coeficientes, pero la regularización no es suficiente para resolver el problema de fondo: las relaciones no son lineales.

7.2.4. Random Forest

El salto de rendimiento es muy significativo: R^2 pasa de 0,635 a 0,963 y el RMSE se reduce de 21.441 a 6.777 kWh/persona. Esto confirma que existen relaciones no lineales fuertes en el consumo per cápita que la regresión lineal no puede capturar pero el Random Forest sí.

7.2.5. Comparación de modelos

Tabla 7.4: Comparación de modelos – Modelo B de consumo energético per cápita.

Modelo	R^2	MAE (kWh/p)	RMSE (kWh/p)
Regresión Lineal	0,6350	12.109	21.441
Ridge ($\alpha = 100$)	0,6313	12.126	21.550
Random Forest (max_depth = 15)	0,9635	3.418	6.777

La diferencia entre los modelos lineales y el Random Forest es contundente (Tabla 7.4). La razón es que el consumo energético per cápita presenta relaciones no lineales con sus determinantes: umbrales, interacciones y rendimientos decrecientes que los modelos lineales no pueden representar.

7.2.6. Importancia de variables - Random Forest

Tabla 7.5: Importancia de variables – Random Forest (consumo per cápita).

Variable	Importancia
gdp_per_capita	0,570
Energy intensity (MJ/\$)	0,186
Renewable energy share (%)	0,085
Land Area (Km ²)	0,078
Electricity from fossil fuels (TWh)	0,038
Access to electricity (%)	0,014
Low-carbon electricity (%)	0,012
Electricity from renewables (TWh)	0,007
Electricity from nuclear (TWh)	0,006
gdp_growth	0,004

El PIB per cápita es el predictor dominante con el 57 % de importancia (Tabla 7.5), seguido de la intensidad energética con el 19 %. Esto es coherente con la idea de que el nivel de desarrollo económico es el principal determinante del consumo energético individual, y confirma la alineación del modelo con los factores de la identidad de Kaya discutidos en el Capítulo 3. El Random Forest con $R^2 = 0,963$ se adopta como modelo final para el consumo per cápita.

Conviene matizar que la importancia de variables en Random Forest mide cuánto contribuye cada variable a reducir el error de predicción en promedio a lo largo de todos los árboles, no el efecto causal de cada variable. Un predictor puede tener alta importancia porque es un buen *proxy* de otros factores no incluidos en el modelo. Además, cuando dos variables están correlacionadas entre sí, la importancia se reparte entre ambas, lo que puede infraestimar la contribución individual de cada una. No obstante, el resultado global — el PIB per cápita como factor dominante — es consistente con la teoría económica y con el marco de la identidad de Kaya, lo que refuerza su validez interpretativa.

7.2.7. Análisis de residuos - Regresión Lineal




Figura 7.2: Residuos de la regresión lineal del modelo de energía per cápita.

El gráfico de residuos (Figura 7.2) y los tests formales revelan:

- **Breusch-Pagan:** $LM = 248,7$ con $p < 0,001$, confirmando heterocedasticidad. Los errores son mayores tanto en los extremos superiores (EE.UU., Australia) como en los inferiores (economías en desarrollo) del rango de consumo.
- **Durbin-Watson:** $d = 0,59$, confirmando autocorrelación positiva, esperable en datos de panel con estructura temporal.

Como en el Modelo A, estas limitaciones afectan a la inferencia estadística pero no a las métricas predictivas ni a las conclusiones del estudio.

7.3. Discusión comparativa de modelos

Los resultados revelan dos dinámicas claramente diferenciadas.

Para las emisiones de CO_2 , el análisis inicial confirmó la estrecha relación entre generación fósil y emisiones ($r \approx 0,99$). El modelo confirmatorio alcanza $R^2 = 0,975$, pero su utilidad es limitada por tratarse de una relación casi redundante. El modelo revisado, que excluye esa variable, alcanza $R^2 = 0,91$ con Ridge y ofrece una visión más genuina de los factores estructurales: la composición del mix eléctrico

(renovables, nuclear) y la intensidad energética de la economía son los principales determinantes cuando se elimina la generación fósil.

Para el consumo energético per cápita, los modelos lineales explican solo el 63 % de la variabilidad, mientras que el Random Forest alcanza $R^2 = 0,963$. Esta diferencia confirma la existencia de relaciones no lineales fuertes, especialmente entre PIB per cápita y consumo (curva de Kuznets ambiental, véase Sección 2.4). El PIB per cápita explica el 57 % de la importancia del modelo, lo que indica que el nivel de desarrollo económico es el factor más determinante del consumo energético individual.

Ambos modelos se evalúan mediante validación interna temporal (entrenamiento hasta 2015, test 2016–2019), la estrategia adecuada para evitar la fuga de información temporal que introduciría una división aleatoria [43].

Capítulo 8

Validación externa y compatibilidad entre datasets

8.1. Motivación

El dataset de Kaggle cubre el periodo 2000–2019, lo que significa que los modelos se entrenaron y evaluaron exclusivamente con datos de ese intervalo. Una extensión natural del trabajo era comprobar si esos modelos son capaces de predecir correctamente en años más recientes, para los que Kaggle no dispone de datos completos.

Con ese objetivo se recurrió al dataset de Our World in Data (OWID) [50], una fuente de referencia internacional a la que ya se ha recurrido en este trabajo y que cubre bien el periodo posterior a 2019. El planteamiento inicial era reentrenar los modelos utilizando todo el periodo disponible en Kaggle (2000–2019) y aplicarlos sobre los datos de OWID para un conjunto de 11 países representativos: China, EE.UU., India, Japón, Alemania, Francia, España, Reino Unido, Brasil, Australia y Rusia.

8.2. Aplicación de los modelos al dataset de OWID

Al aplicar los modelos entrenados con datos de Kaggle sobre las variables equivalentes del dataset de OWID, los resultados fueron inesperadamente incoherentes. Las predicciones del modelo de energía per cápita mostraban desviaciones muy grandes respecto a los valores reales en la mayoría de los países analizados, con errores que no se correspondían con el nivel de precisión demostrado en la validación interna ($R^2 = 0,963$). Había un sesgo de escala evidente que indicaba que el fallo no residía en el modelo, sino en una incompatibilidad de los datos de entrada utilizados.

Esta observación motivó una investigación detallada de la compatibilidad entre ambas fuentes de datos antes de extraer cualquier conclusión.

8.3. Análisis de compatibilidad entre datasets

Para diagnosticar el origen de las discrepancias, se realizó una comparación cruzada de las variables comunes en el año 2019, el último año presente en el dataset de Kaggle, pero podríamos haber escogido cualquier otro a efectos de dicha comparación. Los resultados (Tabla 8.1) revelan principalmente tres situaciones diferenciadas:

1. **Variables eléctricas y consumo per cápita:** coinciden bien entre fuentes, con diferencias inferiores al 3 % en la mayoría de países. Ambos datasets emplean las mismas fuentes primarias (IEA, Ember) para estas variables, lo que explica la concordancia.
2. **PIB per cápita:** se detectan discrepancias de hasta un 70 % en economías emergentes (India 70 %, Brasil 40 %, China 39 %). La causa es que Kaggle utiliza PIB en dólares corrientes (nominales), mientras que OWID lo calcula en dólares constantes de 2017 en paridad de poder adquisitivo (PPA). Son dos formas válidas de medir el PIB, pero en escalas distintas que divergen especialmente en economías donde la diferencia entre PIB nominal y PPA es grande.
3. **Intensidad energética:** discrepancias sistemáticas del orden de 3–4× en todos los países. La razón es la misma: al medir la intensidad como energía consumida por unidad de PIB (MJ/\$), el denominador está en escalas distintas, por lo que el ratio resultante difiere completamente aunque la energía consumida sea la misma.

Tabla 8.1: Comparación de variables entre datasets (año 2019) – Muestra de países.

País	Kaggle	OWID	Dif. %
<i>Energía per cápita (kWh/persona)</i>			
China	28 277	28 232	0,2 %
United States	79 489	78 683	1,0 %
India	6 732	6 682	0,7 %
<i>PIB per cápita (USD)</i>			
China	10 144	16 601	38,9 %
United States	65 280	54 888	18,9 %
India	2 101	6 908	69,6 %
<i>Intensidad energética (MJ/\$)</i>			
	Kaggle	OWID	Factor
China	6,31	1,70	3,7×
United States	4,51	1,43	3,1×
India	4,28	0,97	4,4×

Para el modelo de CO₂ existe además una incompatibilidad adicional: el dataset de energía de OWID (owid-energy-data.csv), que es el que se ha utilizado en

este trabajo, no dispone de una variable equivalente a las emisiones de CO₂ por combustión de fósiles. Solo ofrece una variable de emisiones totales de gases de efecto invernadero (`greenhouse_gas_emissions`), que incluye CO₂, metano, óxido nítrico y otros gases, por lo que no es directamente comparable.

OWID sí publica un dataset específico de emisiones de CO₂ (`owid-co2-data.csv`) que sí incluiría esta variable, pero su integración con las demás variables del modelo habría requerido otro cruce más entre datasets diferentes con sus posibles incoherencias adicionales, por lo que se decide dejar el ejercicio como línea posible de investigación futura.

8.4. Diagnóstico: por qué fallaron las predicciones

El análisis de compatibilidad explica directamente los resultados observados al aplicar los modelos. Las dos variables con mayor importancia en el modelo de energía per cápita son precisamente las que presentan mayor incompatibilidad entre fuentes: el PIB per cápita (57 % de importancia en el Random Forest) y la intensidad energética (19 %). Cuando el modelo recibe valores de PIB e intensidad energética en una escala completamente distinta a la que vio durante el entrenamiento, las predicciones resultan incorrectas aunque el modelo en sí sea correcto: no es el modelo el que falla, sino que los datos de entrada no están en la escala esperada.

8.5. Conclusión

Las incompatibilidades detectadas hacen inviable la validación externa directa sin un proceso previo de armonización que queda fuera del alcance de este trabajo. Dicha armonización requeriría unificar las definiciones de PIB (nominal vs. PPA), recalcular la intensidad energética con el mismo denominador y disponer de una variable de emisiones de CO₂ comparable entre ambas fuentes.

Sin embargo, este resultado constituye en sí mismo un hallazgo metodológico relevante: demuestra que no se pueden combinar libremente datasets energéticos de distintas fuentes sin verificar primero la compatibilidad de las definiciones y escalas de medida.

La validación de los modelos queda apoyada, por tanto, en la validación interna temporal ya realizada en el Capítulo 7, con entrenamiento sobre 2000–2015 y evaluación sobre 2016–2019, todos los datos procedentes del dataset de Kaggle. Esa validación es sólida y los resultados obtenidos ($R^2 = 0,91$ para el modelo de CO₂

revisado, $R^2 = 0,963$ para el modelo de energía per cápita) son representativos de la capacidad real de los modelos.

Esta conclusión tiene implicaciones prácticas para cualquier investigación que pretenda construir modelos predictivos a partir de datos macroeconómicos de múltiples fuentes, y refuerza la importancia de la fase de inspección y verificación de datos en el flujo de trabajo de ciencia de datos.

Capítulo 9

Discusión de resultados

Los resultados del análisis muestran diferencias claras entre la dinámica de las emisiones de CO₂ y la del consumo energético per cápita.

Las emisiones de CO₂ son fundamentalmente un fenómeno de escala: están determinadas por el tamaño absoluto de la economía y su estructura energética. Los modelos lineales capturan esta relación con alta precisión porque los factores determinantes (generación eléctrica, dimensión económica) mantienen relaciones aproximadamente proporcionales con las emisiones a nivel de país.

El consumo per cápita, por el contrario, refleja el nivel de desarrollo y la complejidad socioeconómica de cada país. La relación entre PIB per cápita y consumo energético no es lineal: hay un efecto de saturación en las economías más desarrolladas y un crecimiento acelerado en las economías emergentes. Random Forest captura estas dinámicas al poder modelar interacciones entre variables y umbrales de comportamiento que los modelos lineales no representan.

El análisis temporal confirma que la transición energética global es un proceso lento y gradual, determinado por factores estructurales de inversión, infraestructura y política. No se observa un cambio de tendencia inmediato tras el Acuerdo de París, lo cual es coherente con la naturaleza de los compromisos asumidos, que establecen objetivos a medio y largo plazo.

Desde la perspectiva de la ingeniería mecánica, estos resultados refuerzan la importancia de la eficiencia energética como palanca clave de la descarbonización. Si los modelos muestran que las emisiones son proporcionales a la generación fósil, la vía para reducirlas pasa necesariamente por la sustitución de fuentes fósiles por renovables y la mejora de la eficiencia de conversión energética, áreas donde la ingeniería mecánica tiene un papel protagonista.

Capítulo 10

Conclusiones, limitaciones y líneas futuras

10.1. Conclusiones

1. Se ha realizado un análisis exploratorio exhaustivo del sistema energético global (2000–2019) que revela distribuciones asimétricas, la concentración de emisiones en un grupo reducido de países y una fuerte vinculación entre PIB per cápita y consumo energético.
2. El Modelo A (emisiones de CO₂) alcanza un R² de 0,91 con Ridge tras excluir la generación fósil, demostrando que las emisiones pueden predecirse a partir de variables estructurales sin recurrir a predictores cuasi-tautológicos.
3. El Modelo B (consumo per cápita) alcanza un R² de 0,963 con Random Forest, confirmando la presencia de relaciones no lineales significativas que los modelos lineales no capturan.
4. El análisis temporal no evidencia un cambio de tendencia inmediato tras el Acuerdo de París (2015), lo que es coherente con la naturaleza de largo plazo de la transición energética.
5. El análisis de compatibilidad entre datasets revela incompatibilidades sistemáticas (hasta 70 % en PIB), constituyendo un hallazgo metodológico relevante sobre la necesidad de verificar la armonización de fuentes antes de combinarlas.
6. El trabajo demuestra la viabilidad de aplicar técnicas de *machine learning* al análisis energético global desde una perspectiva de ingeniería mecánica, adquiriendo competencias digitales de alto valor profesional.

10.2. Limitaciones

- Los datos están agregados a nivel país, lo que oculta diferencias entre sectores (industria, transporte, residencial).
- No se han incluido variables como precios de la energía, capacidad instalada o inversión en infraestructuras.
- El periodo analizado (2000–2019) excluye los efectos de la pandemia de COVID-19 sobre el consumo energético.
- No se ha realizado una optimización exhaustiva de hiperparámetros para el Random Forest.
- La validación externa no pudo completarse por incompatibilidades de escala entre fuentes.

10.3. Líneas futuras de investigación

- Ampliar el conjunto de variables con precios de la energía, capacidad instalada renovable e inversión en infraestructuras.
- Desarrollar modelos de series temporales (ARIMA, LSTM) que capturen explícitamente la evolución temporal.
- Aplicar técnicas de clustering para identificar grupos de países con patrones energéticos similares.
- Extender el análisis al periodo 2020–2025 para evaluar el impacto de la pandemia y la recuperación posterior.
- Armonizar los datasets de Kaggle y OWID para completar la validación externa.
- Desarrollar un dashboard interactivo que permita explorar los modelos de forma visual.
- Trasladar el análisis a escala nacional (España), utilizando datos de ESIOS, IDAE e INE.

Bibliografía

- [1] Ge, M., Friedrich, J. y Vigna, L. (2024). Where Do Emissions Come From? 4 Charts Explain Greenhouse Gas Emissions by Sector. *World Resources Institute*. Disponible en: <https://www.wri.org/insights/4-charts-explain-greenhouse-gas-emissions-countries-and-sectors>
- [2] Enerdata. (2025). *Global Energy & Climate Data – Total energy consumption*. Disponible en: <https://yearbook.enerdata.net/total-energy/world-consumption-statistics.html>
- [3] IEA. (2024). *World Energy Outlook 2024*. Disponible en: <https://www.iea.org/reports/world-energy-outlook-2024/pathways-for-the-energy-mix>
- [4] Ministerio para la Transición Ecológica y el Reto Demográfico. (2024). *Plan Nacional Integrado de Energía y Clima (PNIEC) 2023–2030. Actualización*. Aprobado por Real Decreto 986/2024, de 24 de septiembre. Disponible en: <https://www.miteco.gob.es/es/energia/estrategia-normativa/pniec-23-30.html>
- [5] Red Eléctrica de España. (2025). *Informe del sistema eléctrico español 2024 e Informe de energías renovables 2024*. Disponible en: <https://www.ree.es/es/sala-de-prensa/actualidad/nota-de-prensa/2025/03/>
- [6] Naciones Unidas. (2015). *Objetivos de Desarrollo Sostenible*. Disponible en: <https://www.un.org/sustainabledevelopment/es/>
- [7] UNFCCC. (2015). *Acuerdo de París*. Disponible en: <https://unfccc.int/es/acerca-de-las-ndc/el-acuerdo-de-paris>
- [8] Comisión Europea. (2023). *El Pacto Verde Europeo*. Disponible en: https://commission.europa.eu/strategy-and-policy/priorities-2019-2024/european-green-deal_es
- [9] La Moncloa / Gobierno de España. (2024). *El Pacto Verde Europeo: iniciativas para alcanzar la neutralidad climática en la UE*. Disponible en: <https://www.lamoncloa.gob.es/serviciosdeprensa/notasprensa/transicion-ecologica/paginas/2024/que-es-el-pacto-verde-europeo.aspx>
- [10] ISO. (2015). *ISO 14001:2015 — Environmental management systems*. Disponible en: <https://www.iso.org/iso-14001-environmental-management.html>

- [11] ISO. (2018). *ISO 50001:2018 — Energy management systems*. Disponible en: <https://www.iso.org/standard/69426.html>
- [12] GHG Protocol. (2022). *Corporate Standard*. Disponible en: <https://ghgprotocol.org/corporate-standard>
- [13] Wikipedia. (2025). Central hidroeléctrica de El Hierro. Disponible en: https://es.wikipedia.org/wiki/Central_hidroeléctrica_de_El_Hierro. Licencia CC BY-SA.
- [14] Wikimedia Commons. Electric vehicle charging stations in Málaga. Disponible en: https://commons.wikimedia.org/wiki/Category:Electric_vehicle_charging_stations_in_Málaga. Licencia CC BY-SA.
- [15] Our World in Data. *Energy*. Oxford Martin School, University of Oxford / Global Change Data Lab. Disponible en: <https://ourworldindata.org/energy>
- [16] Kuznets, S. (1955). Economic Growth and Income Inequality. *The American Economic Review*, 45(1), 1–28.
- [17] Grossman, G.M. & Krueger, A.B. (1995). Economic Growth and the Environment. *The Quarterly Journal of Economics*, 110(2), 353–377.
- [18] Dinda, S. (2004). Environmental Kuznets Curve Hypothesis: A Survey. *Ecological Economics*, 49(4), 431–455.
- [19] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- [20] Zhao, H. & Magoulès, F. (2012). A review on the prediction of building energy consumption. *Renewable and Sustainable Energy Reviews*, 16(6), 3586–3592. DOI: 10.1016/j.rser.2012.02.049
- [21] Mishra, A., Lone, H.R. & Mishra, A. (2024). DECODE: Data-driven Energy Consumption Prediction leveraging Historical Data and Environmental Factors in Buildings. *Energy and Buildings*, 307, 113950. DOI: 10.1016/j.enbuild.2024.113950
- [22] Kaya, Y. y Yokobori, K. (1997). *Environment, Energy, and Economy: Strategies for Sustainability*. United Nations University Press.
- [23] IPCC. (2022). *Climate Change 2022: Mitigation of Climate Change. Working Group III Contribution to the Sixth Assessment Report*. Cambridge University Press. Disponible en: <https://www.ipcc.ch/report/ar6/wg3/>

-
- [24] Our World in Data. *Kaya identity: drivers of CO₂ emissions*. Oxford Martin School, University of Oxford / Global Change Data Lab. Disponible en: <https://ourworldindata.org/grapher/kaya-identity-co2>. Licencia CC BY.
- [25] Evans, R. y Gao, J. (2016). *DeepMind AI Reduces Google Data Centre Cooling Bill by 40 %*. Google DeepMind Blog. Disponible en: <https://deepmind.google/blog/deepmind-ai-reduces-google-data-centre-cooling-bill-by-40/>
- [26] Tesla. *Opticaster: Intelligent energy optimization*. Disponible en: <https://www.tesla.com/support/energy/tesla-software/opticaster>
- [27] Schneider Electric. (2024). *Industrial artificial intelligence: Optimizing energy efficiency with Predictive AI*. Schneider Electric Blog. Disponible en: <https://blog.se.com/industry/2024/11/29/what-is-predictive-ai/>
- [28] Spacewell Energy (Dexma). *Software de gestión energética*. Disponible en: <https://www.dexma.com/>
- [29] EnergyCAP. *Energy management software*. Disponible en: <https://www.energycap.com/>
- [30] Siemens. *Desigo CC: Building management platform*. Disponible en: <https://www.siemens.com/>
- [31] Cruces Pérez, A. (2025). *Aplicaciones del aprendizaje automático en Ingeniería Mecánica. Mantenimiento Predictivo de un motor a reacción Turbofán*. TFG, Universidad de Málaga.
- [32] Robles de Molina, T. (2025). *Aprendizaje por refuerzo profundo aplicado a datos obtenidos de sensores de IA desarrollados para la industria de defensa*. TFG, Universidad de Málaga.
- [33] Loring Bueno, M. (2025). *Detección automática con redes neuronales profundas de artefactos en superficies fabricadas mediante manufactura aditiva*. TFG, Universidad de Málaga.
- [34] Infante Fernández, S.J. (2025). *Optimización del Consumo Energético en Empresas mediante Inteligencia Artificial y Big Data para la Reducción de la Huella de Carbono*. TFG, Universidad Politécnica de Madrid.
- [35] Python Software Foundation. *Python 3 Documentation*. Disponible en: <https://docs.python.org/3/>
- [36] Google. *Google Colaboratory*. Disponible en: <https://colab.research.google.com/>

- [37] Harris, C.R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
- [38] McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proc. of the 9th Python in Science Conference*, 56–61.
- [39] Hunter, J.D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.
- [40] Waskom, M. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- [41] Seabold, S. & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proc. of the 9th Python in Science Conference*.
- [42] Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- [43] Kaufman, S., Rosset, S., Perlich, C. & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 1–21.
- [44] Montgomery, D.C., Peck, E.A. & Vining, G.G. (2012). *Introduction to Linear Regression Analysis* (5th ed.). Wiley.
- [45] James, G., Witten, D., Hastie, T. & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2nd ed.). Springer. Disponible en: <https://www.statlearning.com/>
- [46] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [47] Breusch, T.S. & Pagan, A.R. (1979). A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 47(5), 1287–1294.
- [48] Durbin, J. & Watson, G.S. (1951). Testing for serial correlation in least squares regression II. *Biometrika*, 38(1/2), 159–177.
- [49] Kaggle. *Global Data on Sustainable Energy* (2000–2020). Disponible en: <https://www.kaggle.com/datasets/anshtanwar/global-data-on-sustainable-energy>
- [50] Our World in Data. *Energy Data – GitHub repository* (archivo `owid-energy-data.csv`). Oxford Martin School, University of Oxford / Global Change Data Lab. Disponible en: <https://github.com/owid/energy-data>

Apéndice A

Código Python completo

A continuación se incluye el código fuente completo del notebook de Google Colab utilizado en este trabajo, organizado según las secciones del análisis.

A.1. COMPRENSIÓN DEL PROBLEMA Y LOS DATOS

El primer paso del análisis consiste en definir el problema, identificar las fuentes de datos y familiarizarse con la estructura del dataset. Esta fase no requiere código específico; las decisiones tomadas se documentan en los Capítulos 5 y 6 de la memoria.

A.2. IMPORTACIÓN DE LIBRERÍAS

```
1  # Importación de librerías
2
3  # Manipulación y análisis de datos
4  import numpy as np          # operaciones numéricas y álgebra lineal
5  import pandas as pd         # manejo de tablas de datos (DataFrames)
6
7  # Visualización
8  import matplotlib.pyplot as plt # gráficos básicos (líneas, barras, dispersión...)
9  import seaborn as sns         # gráficos estadísticos más elaborados
10
11 # Análisis estadístico
12 # variance_inflation_factor: calcula el VIF para detectar multicolinealidad entre
13 from statsmodels.stats.outliers_influence import variance_inflation_factor
14 from statsmodels.stats.stattools import durbin_watson # test de
15 from statsmodels.stats.diagnostic import het_breuschpagan # test de
16 import statsmodels.api as sm # para añadir
17
18 # Preprocesamiento
19 # StandardScaler: estandariza variables para que tengan media=0 y desviación=1
20 # Es especialmente importante para la regresión de Ridge, como se verá más adelante
21 from sklearn.preprocessing import StandardScaler
```

```
22
23 # Modelos
24 from sklearn.linear_model import LinearRegression
25 from sklearn.linear_model import Ridge
26 from sklearn.ensemble import RandomForestRegressor
27
28 # Validación y selección de hiperparámetros
29 # GridSearchCV: prueba sistemáticamente distintos valores de un hiperparámetro
30 # usando validación cruzada para elegir el que mejor generaliza
31 from sklearn.model_selection import GridSearchCV
32
33 # Métricas de evaluación
34 # r2_score: coeficiente de determinación (proporción de variabilidad explicada)
35 # mean_absolute_error: error medio absoluto en las unidades de la variable objetivo
36 # mean_squared_error: error cuadrático medio (penaliza más los errores grandes)
37 from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error
38
39 # Configuración estética para los gráficos (fondo blanco con rejilla)
40 sns.set(style="whitegrid")
```

A.3. CARGA E INSPECCIÓN INICIAL

```
1 # Carga del dataset e inspección inicial
2
3 # Cargamos el CSV con pd.read_csv, que convierte el archivo en un DataFrame de
4 df = pd.read_csv("/content/global-data-on-sustainable-energy (1).csv")
5
6 # df.shape devuelve una tupla (filas, columnas) que nos dice el tamaño del dataset
7 print("Dimensión inicial del dataset:", df.shape)
8
9 # df.head() muestra las 5 primeras filas para hacerse una idea visual de los
10 # que se hayan importado correctamente
11 display(df.head())
12
13 # df.info() muestra el tipo de dato de cada columna y cuántos valores no nulos hay
14 # Es fundamental para detectar columnas con NaN o con tipos incorrectos (p.ej. una
15 # numérica que Python ha leído como texto porque tenía algún carácter extraño)
16 print("\nTipos de datos y valores no nulos:")
17 df.info()
18
19 # df.describe() calcula estadísticas básicas de todas las variables numéricas:
20 # media, desviación típica, mínimo, máximo y percentiles 25, 50 y 75
21 # .transpose() gira la tabla para que cada variable sea una fila, facilitando la
22 print("\nResumen estadístico:")
23 display(df.describe().transpose())
```

```

24
25 # df.duplicated().sum() cuenta cuántas filas son exactamente iguales a otra fila
26 # En datos tipo panel data no debería haber duplicados (cada combinación país-año
27 print("\nNúmero de filas duplicadas:", df.duplicated().sum())

```

A.4. LIMPIEZA DE DATOS

```

1 # Limpieza de datos
2
3 # Estandarización de nombres de columnas
4 # Algunos nombres de columna tienen saltos de línea (\n) o espacios al
5 # que dificultan trabajar con ellos. Los limpiamos con str.replace y str.strip
6 df.columns = df.columns.str.replace("\n", " ", regex=False).str.strip()
7
8 # Renombramos la columna de densidad que tiene un nombre con caracteres especiales
9 if "Density (P/Km2)" in df.columns:
10     df.rename(columns={"Density (P/Km2)": "Density"}, inplace=True)
11
12 # Corrección de tipos de datos
13 # La columna Density se leyó como texto (object) porque tenía comas como separador
14 # Primero quitamos las comas y luego convertimos a numérico con pd.to_numeric
15 # errors="coerce" convierte a NaN cualquier valor que no se pueda convertir (en
16 if "Density" in df.columns:
17     df["Density"] = (
18         df["Density"]
19         .astype(str) # aseguramos que sea texto para poder usar
20         .str.replace(",", "", regex=False) # quitamos las comas separadoras de
21     )
22     df["Density"] = pd.to_numeric(df["Density"], errors="coerce")
23
24 # Análisis de valores faltantes
25 # df.isna().sum() cuenta los NaN por columna
26 # .sort_values() los ordena de más a menos para ver rápidamente qué columnas
27 missing_values = df.isna().sum().sort_values(ascending=False)
28
29 print("Valores faltantes por variable:\n")
30 print(missing_values[missing_values > 0]) # solo mostramos las columnas con algún
31
32 # Eliminación de columnas con demasiados valores faltantes
33 # Umbral del 40%: si más del 40% de los valores de una columna son NaN, la
34 # porque imputar tantos datos sería poco fiable
35 threshold = 0.4 * len(df)
36 cols_to_drop = missing_values[missing_values > threshold].index.tolist()
37
38 if cols_to_drop:

```

```

39     print("\nColumnas eliminadas por tener más del 40% de valores faltantes:")
40     print(cols_to_drop)
41     df.drop(columns=cols_to_drop, inplace=True) # inplace=True modifica df
42
43     # Imputación de valores faltantes
44     # Protegemos las variables objetivo: No se imputan, porque si rellenamos
45     # el CO2 o el consumo per cápita estaríamos inventando lo que queremos predecir
46     target_vars = [
47         "Value_co2_emissions_kt_by_country",
48         "Primary energy consumption per capita (kWh/person)"
49     ]
50
51     # Para el resto de variables numéricas hacemos imputación en dos pasos:
52     numeric_cols = df.select_dtypes(include=np.number).columns
53
54     for col in numeric_cols:
55         if col not in target_vars:
56             # Paso 1: rellenamos con la media de ese mismo país a lo largo del tiempo
57             # groupby("Entity") agrupa las filas de cada país, transform calcula la
58             # por grupo y la devuelve en el mismo índice que el DataFrame original
59             df[col] = df.groupby("Entity")[col].transform(
60                 lambda x: x.fillna(x.mean())
61             )
62             # Paso 2: si después del paso 1 aún quedan NaN (p.ej. un país sin ningún
63             # rellenamos con la media global de toda la variable
64             df[col] = df[col].fillna(df[col].mean())
65
66     # Eliminación de filas sin variable objetivo
67     # Después de imputar predictores, eliminamos las filas donde CO2 o consumo per
68     # siguen siendo NaN. No podemos entrenar con observaciones sin variable objetivo.
69     df = df.dropna(subset=target_vars).copy()
70
71     # Comprobación final
72     duplicates = df.duplicated().sum()
73     print("\nFilas duplicadas:", duplicates)
74     if duplicates > 0:
75         df = df.drop_duplicates()
76
77     print("\nDimensión final del dataset:", df.shape)
78     print("\nTotal de valores faltantes restantes:", df.isna().sum().sum())

```

A.5. ANÁLISIS UNIVARIADO

A.5.1. Distribución de emisiones de CO₂

```
1 # Distribución de emisiones de CO2
2
3 # sns.histplot dibuja un histograma de la variable especificada
4 # bins=40 controla el número de barras (cuanto más barras, mayor detalle)
5 # kde=True añade una curva de densidad suavizada encima del histograma
6 plt.figure(figsize=(8,6))
7 sns.histplot(df["Value_co2_emissions_kt_by_country"], bins=40, kde=True)
8
9 plt.title("Distribución de emisiones de CO2 (kt)")
10 plt.xlabel("CO2 (kt)")
11 plt.ylabel("Frecuencia")
12 plt.show()
13
14 # .skew() calcula el coeficiente de asimetría: positivo = cola a la derecha,
15 df["Value_co2_emissions_kt_by_country"].skew()
```

A.5.2. Distribución del consumo energético per cápita

```
1 # Distribución del consumo energético per cápita
2 # Mismo esquema que el histograma anterior, aplicado a la segunda variable objetivo
3
4 plt.figure(figsize=(8,6))
5 sns.histplot(
6     df["Primary energy consumption per capita (kWh/person)"],
7     bins=40, kde=True)
8
9 plt.title("Distribución del consumo energético per cápita")
10 plt.xlabel("kWh por persona")
11 plt.ylabel("Frecuencia")
12 plt.show()
13
14 df["Primary energy consumption per capita (kWh/person)"].skew()
```

A.5.3. Distribución del PIB per cápita

```
1 # Distribución del PIB per cápita
2
3 plt.figure(figsize=(8,6))
```

```
4 sns.histplot(df["gdp_per_capita"], bins=40, kde=True)
5
6 plt.title("Distribución del PIB per cápita")
7 plt.xlabel("PIB per cápita (USD)")
8 plt.ylabel("Frecuencia")
9 plt.show()
10
11 df["gdp_per_capita"].skew()
```

A.6. DETECCIÓN DE OUTLIERS

A.6.1. Boxplot de emisiones de CO₂

```
1 # Boxplot de emisiones de CO2
2 # El boxplot muestra la mediana (línea central), el rango intercuartílico IQR (caja)
3 # y los valores extremos (puntos individuales fuera de los bigotes)
4 # Es más informativo que el histograma para detectar outliers
5
6 plt.figure(figsize=(10,4))
7 sns.boxplot(x=df["Value_co2_emissions_kt_by_country"])
8
9 plt.title("Boxplot - Emisiones de CO2")
10 plt.xlabel("CO2 (kt)")
11 plt.show()
```

A.6.2. Boxplot de consumo energético per cápita

```
1 # Boxplot de consumo energético per cápita
2
3 plt.figure(figsize=(10,4))
4 sns.boxplot(x=df["Primary energy consumption per capita (kWh/person)"])
5
6 plt.title("Boxplot - Consumo energético per cápita")
7 plt.xlabel("kWh por persona")
8 plt.show()
```

A.7. ANÁLISIS BIVARIADO Y MULTIVARIADO

A.7.1. Análisis de correlaciones

```

1 # Análisis de correlaciones
2
3 # Seleccionamos las columnas numéricas para calcular las correlaciones
4 numeric_df = df.select_dtypes(include=np.number)
5
6 # Calculamos la matriz de correlaciones con .corr()
7 # Visualizamos con un mapa de calor
8 # coolwarm: azul para correlaciones negativas, rojo para positivas, blanco para cero
9 # center=0 asegura que el blanco corresponda exactamente a correlación = 0
10 plt.figure(figsize=(14,10))
11 sns.heatmap(
12     numeric_df.corr(),
13     cmap="coolwarm",
14     center=0,
15     linewidths=0.5
16 )
17
18 plt.title("Matriz de correlaciones")
19 plt.show()

```

Correlación con emisiones de CO₂

```

1 # Correlación de todas las variables con las emisiones de CO2
2 # .corr() calcula la correlación de cada variable con todas las demás
3 # Seleccionamos solo la columna del CO2 y ordenamos de mayor a menor
4 corr_co2 = (
5     numeric_df
6     .corr()["Value_co2_emissions_kt_by_country"] # columna con correlaciones vs
7     .sort_values(ascending=False)              # ordenar de mayor a menor
8 )
9
10 print(corr_co2)

```

Correlación con consumo energético per cápita

```

1 # Correlación de todas las variables con el consumo energético per cápita
2 # Mismo procedimiento que para CO2:
3
4 corr_energy = (
5     numeric_df
6     .corr()["Primary energy consumption per capita (kWh/person)"]
7     .sort_values(ascending=False)
8 )
9

```

```
10 print(corr_energy)
```

A.7.2. Detección de redundancia entre variables

```
1 # Detección de redundancia entre variables (correlación > 0.9)
2
3 # Calculamos la matriz de correlaciones en valor absoluto
4 corr_matrix = numeric_df.corr().abs()
5
6 # Extraemos solo el triángulo superior de la matriz para no contar cada par dos
7 # np.triu crea una matriz de unos en el triángulo superior, k=1 excluye la diagonal
8 upper_triangle = corr_matrix.where(
9     np.triu(np.ones(corr_matrix.shape), k=1).astype(bool)
10 )
11
12 # Identificamos las variables que tienen alguna correlación > 0.9 con otra variable
13 high_corr_vars = [
14     col for col in upper_triangle.columns
15     if any(upper_triangle[col] > 0.9)
16 ]
17
18 print("Variables con correlación > 0.9 con alguna otra variable:")
19 print(high_corr_vars)
```

A.7.3. Análisis de multicolinealidad (VIF)

Modelo de emisiones de CO₂

```
1 # Análisis VIF - Modelo de emisiones de CO2
2
3 # variance_inflation_factor de statsmodels calcula el VIF de cada variable
4 # dado el conjunto completo de predictores
5
6 # Lista de variables predictoras en el modelo de CO2
7 features_co2 = [
8     "Year",
9     "Electricity from fossil fuels (TWh)",
10    "Electricity from nuclear (TWh)",
11    "Electricity from renewables (TWh)",
12    "Renewable energy share in the total final energy consumption (%)",
13    "Low-carbon electricity (% electricity)",
14    "Energy intensity level of primary energy (MJ/$2017 PPP GDP)"
15 ]
```



```

16
17 # Creamos un DataFrame solo con esas variables para calcular el VIF
18 X_co2_vif = df[features_co2]
19
20 # Calculamos el VIF para cada variable en su posición i
21 # variance_inflation_factor recibe la matriz completa y el índice de la columna a
22 vif_data_co2 = pd.DataFrame()
23 vif_data_co2["Feature"] = X_co2_vif.columns
24 vif_data_co2["VIF"] = [
25     variance_inflation_factor(X_co2_vif.values, i)
26     for i in range(X_co2_vif.shape[1])
27 ]
28
29 # Mostramos ordenado de mayor a menor VIF
30 print(vif_data_co2.sort_values("VIF", ascending=False))

```

Modelo de consumo energético per cápita

```

1 # Análisis VIF - Modelo de consumo energético per cápita (segunda iteración - sin
2
3 features_energy_refined = [
4     "gdp_per_capita",
5     "gdp_growth",
6     "Electricity from fossil fuels (TWh)",
7     "Electricity from nuclear (TWh)",
8     "Electricity from renewables (TWh)",
9     "Renewable energy share in the total final energy consumption (%)",
10    "Low-carbon electricity (% electricity)",
11    "Energy intensity level of primary energy (MJ/$2017 PPP GDP)",
12    "Access to electricity (% of population)",
13    "Land Area(Km2)"
14 ]
15
16 X_energy_refined = df[features_energy_refined]
17
18 # Mismo cálculo de VIF que para el modelo de CO2
19 vif_data_energy = pd.DataFrame()
20 vif_data_energy["Feature"] = X_energy_refined.columns
21 vif_data_energy["VIF"] = [
22     variance_inflation_factor(X_energy_refined.values, i)
23     for i in range(X_energy_refined.shape[1])
24 ]
25
26 print(vif_data_energy.sort_values("VIF", ascending=False))

```

A.8. ANÁLISIS TEMPORAL GLOBAL

A.8.1. Evolución global de emisiones de CO₂

```

1 # Evolución temporal de las emisiones globales de CO2
2
3 # Agrupamos por año y sumamos las emisiones de todos los países
4 # Esto nos da las emisiones totales mundiales para cada año
5 global_co2 = (
6     df[df["Year"] < 2020]                                # solo años hasta 2019
7     .groupby("Year", as_index=False)                      # agrupamos por año
8     ["Value_co2_emissions_kt_by_country"]
9     .sum()                                                 # sumamos las emisiones
10 )
11
12 plt.figure(figsize=(10,6))
13 plt.plot(global_co2["Year"], global_co2["Value_co2_emissions_kt_by_country"])
14
15 plt.title("Emisiones globales totales de CO2 (2000-2019)")
16 plt.xlabel("Año")
17 plt.ylabel("CO2 total (kt)")
18 plt.xticks(global_co2["Year"], rotation=45) # un tick por año, rotados 45° para
19 plt.grid(True)
20 plt.show()

```

A.8.2. Evolución global de la proporción de energías renovables

```

1 # Evolución temporal de la proporción media de energías renovables
2
3 # Agrupamos por año y calculamos la media
4 global_renew = (
5     df[df["Year"] < 2020]
6     .groupby("Year", as_index=False)
7     ["Renewable energy share in the total final energy consumption (%)"]
8     .mean() # media de todos los países ese año
9 )
10
11 plt.figure(figsize=(10,6))
12 plt.plot(
13     global_renew["Year"],
14     global_renew["Renewable energy share in the total final energy consumption (%)"]
15 )
16
17 plt.title("Cuota media global de energías renovables (2000-2019)")

```

```

18 plt.xlabel("Año")
19 plt.ylabel("Proporción de renovables (%)")
20 plt.xticks(global_renew["Year"], rotation=45)
21 plt.grid(True)
22 plt.show()

```

A.8.3. Referencia temporal: Acuerdo de París (2015)

Emisiones globales con referencia a 2015

```

1 # Emisiones globales con referencia al Acuerdo de París (2015)
2
3 plt.figure(figsize=(10,6))
4 plt.plot(global_co2["Year"],
5          global_co2["Value_co2_emissions_kt_by_country"],
6          label="CO2 global")
7
8 # plt.axvline dibuja una línea vertical en x=2015 para marcar el año del Acuerdo
9 plt.axvline(x=2015, color="red", linestyle="--", label="Acuerdo de París (2015)")
10
11 plt.title("Emisiones globales de CO2 (2000-2019)")
12 plt.xlabel("Año")
13 plt.ylabel("CO2 total (kt)")
14 plt.legend()
15 plt.xticks(global_co2["Year"], rotation=45)
16 plt.grid(True)
17 plt.show()

```

Proporción renovable con referencia a 2015

```

1 # Cuota renovable con referencia al Acuerdo de París (2015)
2
3 plt.figure(figsize=(10,6))
4 plt.plot(
5     global_renew["Year"],
6     global_renew[
7         "Renewable energy share in the total final"
8         " energy consumption (%)"],
9     label="Cuota renovable"
10 )
11
12 plt.axvline(x=2015, color="red", linestyle="--", label="Acuerdo de París (2015)")
13
14 plt.title("Cuota media global de renovables (2000-2019)")

```

```
15 plt.xlabel("Año")
16 plt.ylabel("Renovables (%)")
17 plt.legend()
18 plt.xticks(global_renew["Year"], rotation=45)
19 plt.grid(True)
20 plt.show()
```

A.8.4. Comparación antes y después de 2015

```
1 # Comparación estadística antes y después de 2015
2
3 # Calculamos la media de emisiones en los dos periodos para ver si hay cambio
4 co2_before = (global_co2[global_co2["Year"] < 2015]
5               ["Value_co2_emissions_kt_by_country"].mean())
6 co2_after = (global_co2[global_co2["Year"] >= 2015]
7              ["Value_co2_emissions_kt_by_country"].mean())
8
9 print("Promedio CO2 antes de 2015:", round(co2_before, 0), "kt")
10 print("Promedio CO2 después de 2015:", round(co2_after, 0), "kt")
11
12 # Lo mismo para la cuota de renovables
13 col_renew = ("Renewable energy share in the total"
14             " final energy consumption (%)")
15 renew_before = (global_renew[global_renew["Year"] < 2015]
16                [col_renew].mean())
17 renew_after = (global_renew[global_renew["Year"] >= 2015]
18               [col_renew].mean())
19
20 print("\nCuota renovable antes de 2015:", round(renew_before, 2), "%")
21 print("Cuota renovable después de 2015:", round(renew_after, 2), "%")
```

A.9. MODELADO PREDICTIVO – MODELO A: EMISIONES DE CO₂

A.9.1. Preparación de datos

```
1 # Preparación de datos - Modelo de emisiones de CO2
2
3 # Lista de variables explicativas seleccionadas en el análisis exploratorio
4 features_co2_final = [
5     "Year",
```

```

6     "Electricity from fossil fuels (TWh)",
7     "Electricity from nuclear (TWh)",
8     "Electricity from renewables (TWh)",
9     "Renewable energy share in the total final energy consumption (%)",
10    "Low-carbon electricity (% electricity)",
11    "Energy intensity level of primary energy (MJ/$2017 PPP GDP)"
12 ]
13
14 # Variable que queremos predecir
15 target_co2 = "Value_co2_emissions_kt_by_country"
16
17 # División temporal: train hasta 2015 inclusive, test 2016-2019
18 train_df = df[df["Year"] <= 2015]
19 test_df = df[df["Year"] > 2015]
20
21 # Separamos predictores (X) y variable objetivo (y) para cada conjunto
22 X_train_co2 = train_df[features_co2_final]
23 y_train_co2 = train_df[target_co2]
24
25 X_test_co2 = test_df[features_co2_final]
26 y_test_co2 = test_df[target_co2]
27
28 # Estandarización de las variables explicativas (StandardScaler)
29 # El scaler se ajusta solo con los datos de entrenamiento (.fit_transform) y se
30 # aplica sin reajustar al conjunto de test (.transform), para evitar cualquier
31 # fuga de información del test al entrenamiento.
32 scaler_co2 = StandardScaler()
33 X_train_co2_scaled = scaler_co2.fit_transform(X_train_co2) # ajusta y transforma
34 X_test_co2_scaled = scaler_co2.transform(X_test_co2)      # solo transforma el
35
36 print("Train shape:", X_train_co2_scaled.shape)
37 print("Test shape:", X_test_co2_scaled.shape)

```

A.9.2. Regresión lineal múltiple

```

1 # Regresión lineal - Modelo CO2
2
3 # .fit() ajusta los coeficientes minimizando la suma de errores cuadráticos
4 linreg_co2 = LinearRegression()
5 linreg_co2.fit(X_train_co2_scaled, y_train_co2)
6
7 # .predict() aplica el modelo entrenado a los datos de test escalados
8 y_pred_co2 = linreg_co2.predict(X_test_co2_scaled)
9
10 # Calculamos las métricas comparando predicciones con valores reales del test

```

```
11 r2_co2 = r2_score(y_test_co2, y_pred_co2)
12 mae_co2 = mean_absolute_error(y_test_co2, y_pred_co2)
13 rmse_co2 = np.sqrt(mean_squared_error(y_test_co2, y_pred_co2))
14
15 print("Resultados - Modelo CO2 (Regresión Lineal)")
16 print("R2: ", round(r2_co2, 4))
17 print("MAE: ", round(mae_co2, 0), "kt")
18 print("RMSE:", round(rmse_co2, 0), "kt")
```

Interpretación de coeficientes

```
1 # Coeficientes de la regresión lineal para el modelo de CO2
2
3 # Los coeficientes se interpretan sobre las variables estandarizadas:
4 # cuántas unidades cambia el CO2 predicho cuando esa variable
5 # sube en una desviación típica, manteniendo el resto constante
6 coef_df_co2 = pd.DataFrame({
7     "Feature": features_co2_final,
8     "Coefficient": linreg_co2.coef_
9 })
10
11 print(coef_df_co2)
12
13 # El intercept es el valor predicho cuando todos los predictores son cero
14 print("Intercept:", linreg_co2.intercept_)
```

Análisis de residuos

```
1 # Análisis de residuos - Modelo lineal CO2
2
3 # Los residuos son la diferencia entre el valor real y el predicho
4 # Si el modelo es bueno, deberían estar centrados en cero y sin ningún patrón
5 residuals_co2 = y_test_co2 - y_pred_co2
6
7 # Gráfico de residuos vs valores predichos:
8 # si hay un patrón (embudo, curva), indica problemas en el modelo
9 plt.figure(figsize=(8,6))
10 sns.scatterplot(x=y_pred_co2, y=residuals_co2, alpha=0.4)
11
12 # Línea horizontal en y=0: los residuos deberían distribuirse simétricamente
13 plt.axhline(0, color='red', linestyle='--')
14 plt.xlabel("CO2 predicho (kt)")
15 plt.ylabel("Residuos (real - predicho)")
16 plt.title("Residuos vs valores predichos - Modelo CO2")
```

```
17 plt.show()
```

Diagnóstico formal de residuos

```
1 # Diagnóstico formal de residuos - Modelo CO2
2 # Dos tests para cuantificar los patrones observados en el gráfico de residuos:
3
4 # Test de Breusch-Pagan (heterocedasticidad)
5 # Contrasta si la varianza de los residuos es constante (homocedasticidad)
6 # o varía en función de los predictores (heterocedasticidad).
7 # Regresa los residuos al cuadrado sobre las variables explicativas y calcula
8 # el estadístico LM = n x R2 de esa regresión auxiliar.
9 # Un p-valor < 0.05 indica heterocedasticidad.
10 # Usamos las variables escaladas (X_test_co2_scaled), que son las que el modelo ha
11 # sm.add_constant añade una columna de unos necesaria para la regresión auxiliar
12 lm_co2, p_bp_co2, _, _ = het_breuschpagan(
13     residuals_co2, sm.add_constant(X_test_co2_scaled))
14
15 print("Test de Breusch-Pagan (heterocedasticidad)")
16 print(f"Estadístico LM: {lm_co2:.3f}")
17 print(f"p-valor:      {p_bp_co2:.4f}")
18 print()
19
20 # Test de Durbin-Watson (autocorrelación temporal)
21 # Detecta si los residuos consecutivos están correlacionados entre sí.
22 # Valor ideal = 2 (sin autocorrelación);
23 # Valores < 1.5 indican autocorrelación positiva (habitual en panel data)
24 dw_co2 = durbin_watson(residuals_co2)
25
26 print("Test de Durbin-Watson (autocorrelación)")
27 print(f"Estadístico DW: {dw_co2:.3f} (valor ideal = 2)")
```

A.9.3. Ridge Regression

```
1 # Ridge Regression - Modelo CO2
2
3 # Los datos ya están estandarizados desde la celda de preparación,
4 # por lo que Ridge recibe directamente X_train_co2_scaled y X_test_co2_scaled.
5 # El GridSearchCV busca el mejor valor de  $\alpha$  (fuerza de regularización)
6 # mediante validación cruzada de 5 folds sobre el conjunto de entrenamiento.
7 #  $\alpha=0$  equivale a regresión lineal; cuanto mayor es  $\alpha$ , más se penalizan
8 # los coeficientes hacia cero.
9 grid_ridge_co2 = GridSearchCV(
10     Ridge(),
```

```
11     {"alpha": [0.01, 0.1, 1, 10, 100, 1000]},
12     cv=5,
13     scoring="r2"
14 )
15
16 # Entrenamos el GridSearchCV: busca el mejor  $\alpha$  y entrena el modelo final con ese  $\alpha$ 
17 grid_ridge_co2.fit(X_train_co2_scaled, y_train_co2)
18
19 # best_estimator_ es el modelo con el mejor  $\alpha$  encontrado
20 best_ridge = grid_ridge_co2.best_estimator_
21
22 # Aplicamos el modelo al test
23 y_pred_ridge = best_ridge.predict(X_test_co2_scaled)
24
25 r2_ridge = r2_score(y_test_co2, y_pred_ridge)
26 mae_ridge = mean_absolute_error(y_test_co2, y_pred_ridge)
27 rmse_ridge = np.sqrt(mean_squared_error(y_test_co2, y_pred_ridge))
28
29 print("Mejor  $\alpha$ :", grid_ridge_co2.best_params_)
30 print("R2: ", round(r2_ridge, 4))
31 print("MAE: ", round(mae_ridge, 0), "kt")
32 print("RMSE: ", round(rmse_ridge, 0), "kt")
```

Coeficientes Ridge

```
1 # Coeficientes Ridge - Modelo CO2
2
3 # Los coeficientes se acceden directamente desde best_ridge
4 ridge_coefs = best_ridge.coef_
5
6 coef_df_ridge = pd.DataFrame({
7     "Feature": features_co2_final,
8     "Ridge Coefficient": ridge_coefs
9 })
10
11 print(coef_df_ridge)
```

A.9.4. Random Forest

```
1 # Random Forest - Modelo CO2
2
3 # Random Forest es invariante a la escala de las variables (los árboles de decisión
4 # trabajan con umbrales, no con magnitudes), por lo que el escalado no cambia el
5 # De todas formas, usamos X_train_co2_scaled por coherencia metodológica con los
```



```

6
7 # Definimos los valores de max_depth que queremos probar
8 # max_depth controla la profundidad máxima de cada árbol:
9 # - valores pequeños (5, 10): árboles sencillos, menos riesgo de sobreajuste pero
10 # - None: los árboles crecen sin límite, pueden memorizar el entrenamiento
11 # GridSearchCV elegirá el que mejor generalice en validación cruzada
12 param_grid_rf_co2 = {
13     "max_depth": [5, 10, 15, 20, None]
14 }
15
16 # n_estimators=300: construimos 300 árboles de decisión distintos
17 # Más árboles = más estabilidad, pero más tiempo de cómputo
18 # random_state=42: fija la semilla aleatoria para que los resultados sean
19 # n_jobs=-1: usa todos los núcleos del procesador en paralelo para ir más rápido
20 rf_co2_base = RandomForestRegressor(
21     n_estimators=300,
22     random_state=42,
23     n_jobs=-1
24 )
25
26 # Buscamos el mejor max_depth con validación cruzada de 5 folds
27 grid_rf_co2 = GridSearchCV(
28     rf_co2_base,
29     param_grid_rf_co2,
30     cv=5,
31     scoring="r2"
32 )
33
34 grid_rf_co2.fit(X_train_co2_scaled, y_train_co2)
35 rf_co2 = grid_rf_co2.best_estimator_ # modelo final con el mejor max_depth
36
37 y_pred_rf = rf_co2.predict(X_test_co2_scaled)
38
39 r2_rf = r2_score(y_test_co2, y_pred_rf)
40 mae_rf = mean_absolute_error(y_test_co2, y_pred_rf)
41 rmse_rf = np.sqrt(mean_squared_error(y_test_co2, y_pred_rf))
42
43 print("Mejor max_depth:", grid_rf_co2.best_params_)
44 print("R2: ", round(r2_rf, 4))
45 print("MAE: ", round(mae_rf, 0), "kt")
46 print("RMSE:", round(rmse_rf, 0), "kt")

```

Importancia de variables

```

1 # Importancia de variables - Random Forest CO2
2

```

```
3 # feature_importances_ devuelve un array con la importancia de cada variable
4 # La importancia mide cuánto reduce el error de predicción cada variable
5 # en promedio a lo largo de todos los árboles del bosque
6 # Los valores suman 1
7 importances = rf_co2.feature_importances_
8
9 # DataFrame para verlo más claro
10 importance_df = pd.DataFrame({
11     "Feature": features_co2_final,
12     "Importance": importances
13 }).sort_values(by="Importance", ascending=False) # ordenamos de más a menos
14
15 print(importance_df)
```

A.9.5. Modelo CO₂ revisado — sin generación fósil

```
1 # Preparación de datos - Modelo CO2 revisado (sin generación fósil)
2
3 features_co2_revised = [
4     "Year",
5     "Electricity from nuclear (TWh)",
6     "Electricity from renewables (TWh)",
7     "Renewable energy share in the total final energy consumption (%)",
8     "Low-carbon electricity (% electricity)",
9     "Energy intensity level of primary energy (MJ/$2017 PPP GDP)"
10 ]
11
12 target_co2 = "Value_co2_emissions_kt_by_country"
13
14 # Misma división temporal que el modelo original
15 X_train_co2_rev = train_df[features_co2_revised]
16 y_train_co2_rev = train_df[target_co2]
17
18 X_test_co2_rev = test_df[features_co2_revised]
19 y_test_co2_rev = test_df[target_co2]
20
21 # Estandarización -- mismo criterio que el modelo original:
22 # el scaler se ajusta con el train y se aplica al test sin reajustar
23 scaler_co2_rev = StandardScaler()
24 X_train_co2_rev_scaled = scaler_co2_rev.fit_transform(X_train_co2_rev)
25 X_test_co2_rev_scaled = scaler_co2_rev.transform(X_test_co2_rev)
26
27 print("Train shape:", X_train_co2_rev_scaled.shape)
28 print("Test shape:", X_test_co2_rev_scaled.shape)
```

Regresión lineal – CO₂ revisado

```

1 # Regresión lineal - Modelo CO2 revisado
2
3 # Seguimos el mismo procedimiento que para el modelo original:
4 # creamos el objeto, lo entrenamos con .fit(), predecimos con .predict() y
5 linreg_co2_rev = LinearRegression()
6 linreg_co2_rev.fit(X_train_co2_rev_scaled, y_train_co2_rev)
7
8 y_pred_co2_rev = linreg_co2_rev.predict(X_test_co2_rev_scaled)
9
10 r2_co2_rev = r2_score(y_test_co2_rev, y_pred_co2_rev)
11 mae_co2_rev = mean_absolute_error(y_test_co2_rev, y_pred_co2_rev)
12 rmse_co2_rev = np.sqrt(mean_squared_error(y_test_co2_rev, y_pred_co2_rev))
13
14 print("Regresión Lineal - Modelo CO2 revisado")
15 print("R2: ", round(r2_co2_rev, 4))
16 print("MAE: ", round(mae_co2_rev, 0), "kt")
17 print("RMSE:", round(rmse_co2_rev, 0), "kt")

```

Ridge Regression – CO₂ revisado

```

1 # Ridge Regression - Modelo CO2 revisado
2
3 grid_ridge_rev = GridSearchCV(
4     Ridge(),
5     {"alpha": [0.01, 0.1, 1, 10, 100, 1000]},
6     cv=5,
7     scoring="r2"
8 )
9
10 grid_ridge_rev.fit(X_train_co2_rev_scaled, y_train_co2_rev)
11 best_ridge_rev = grid_ridge_rev.best_estimator_
12
13 y_pred_ridge_rev = best_ridge_rev.predict(X_test_co2_rev_scaled)
14
15 r2_ridge_rev = r2_score(y_test_co2_rev, y_pred_ridge_rev)
16 mae_ridge_rev = mean_absolute_error(y_test_co2_rev, y_pred_ridge_rev)
17 rmse_ridge_rev = np.sqrt(mean_squared_error(y_test_co2_rev, y_pred_ridge_rev))
18
19 print("Mejor  $\alpha$ :", grid_ridge_rev.best_params_)
20 print("R2: ", round(r2_ridge_rev, 4))
21 print("MAE: ", round(mae_ridge_rev, 0), "kt")
22 print("RMSE:", round(rmse_ridge_rev, 0), "kt")

```

Random Forest – CO₂ revisado

```

1  # Random Forest - Modelo CO2 revisado
2
3  param_grid_rf_co2_rev = {
4      "max_depth": [5, 10, 15, 20, None]
5  }
6
7  rf_co2_rev_base = RandomForestRegressor(
8      n_estimators=300,
9      random_state=42,
10     n_jobs=-1
11 )
12
13 grid_rf_co2_rev = GridSearchCV(
14     rf_co2_rev_base,
15     param_grid_rf_co2_rev,
16     cv=5,
17     scoring="r2"
18 )
19
20 grid_rf_co2_rev.fit(X_train_co2_rev_scaled, y_train_co2_rev)
21 rf_co2_rev = grid_rf_co2_rev.best_estimator_
22
23 y_pred_rf_rev = rf_co2_rev.predict(X_test_co2_rev_scaled)
24
25 r2_rf_rev = r2_score(y_test_co2_rev, y_pred_rf_rev)
26 mae_rf_rev = mean_absolute_error(y_test_co2_rev, y_pred_rf_rev)
27 rmse_rf_rev = np.sqrt(mean_squared_error(y_test_co2_rev, y_pred_rf_rev))
28
29 print("Mejor max_depth:", grid_rf_co2_rev.best_params_)
30 print("R2: ", round(r2_rf_rev, 4))
31 print("MAE: ", round(mae_rf_rev, 0), "kt")
32 print("RMSE:", round(rmse_rf_rev, 0), "kt")
33
34 # Importancia de variables del modelo revisado
35 importances_rev = pd.DataFrame({
36     "Feature": features_co2_revised,
37     "Importance": rf_co2_rev.feature_importances_
38 }).sort_values("Importance", ascending=False)
39
40 print("\nImportancia de variables:")
41 print(importances_rev.to_string(index=False))

```

A.10. MODELADO PREDICTIVO – MODELO B: CONSUMO ENERGÉTICO PER CÁPITA

A.10.1. Preparación de datos

```
1 # Preparación de datos - Modelo de consumo energético per cápita
2
3 features_energy_final = [
4     "gdp_per_capita",
5     "gdp_growth",
6     "Electricity from fossil fuels (TWh)",
7     "Electricity from nuclear (TWh)",
8     "Electricity from renewables (TWh)",
9     "Renewable energy share in the total final energy consumption (%)",
10    "Low-carbon electricity (% electricity)",
11    "Energy intensity level of primary energy (MJ/$2017 PPP GDP)",
12    "Access to electricity (% of population)",
13    "Land Area(Km2)"
14 ]
15
16 target_energy = "Primary energy consumption per capita (kWh/person)"
17
18 # Misma división temporal que el modelo de CO2
19 train_df = df[df["Year"] <= 2015]
20 test_df = df[df["Year"] > 2015]
21
22 X_train_energy = train_df[features_energy_final]
23 y_train_energy = train_df[target_energy]
24
25 X_test_energy = test_df[features_energy_final]
26 y_test_energy = test_df[target_energy]
27
28 # Estandarización -- mismo criterio que el modelo de CO2
29 # Especialmente importante para Ridge, pero se aplica a todos los modelos
30 scaler_energy = StandardScaler()
31 X_train_energy_scaled = scaler_energy.fit_transform(X_train_energy)
32 X_test_energy_scaled = scaler_energy.transform(X_test_energy)
33
34 print("Train shape:", X_train_energy_scaled.shape)
35 print("Test shape:", X_test_energy_scaled.shape)
```

A.10.2. Regresión lineal múltiple

```
1 # Regresión lineal - Modelo de energía per cápita
2
3 # Mismo esquema que el modelo de CO2: fit → predict → métricas
4 linreg_energy = LinearRegression()
5 linreg_energy.fit(X_train_energy_scaled, y_train_energy)
6
7 y_pred_energy = linreg_energy.predict(X_test_energy_scaled)
8
9 r2_energy = r2_score(y_test_energy, y_pred_energy)
10 mae_energy = mean_absolute_error(y_test_energy, y_pred_energy)
11 rmse_energy = np.sqrt(mean_squared_error(y_test_energy, y_pred_energy))
12
13 print("Regresión Lineal - Modelo de energía")
14 print("R2: ", round(r2_energy, 4))
15 print("MAE: ", round(mae_energy, 0), "kWh/persona")
16 print("RMSE: ", round(rmse_energy, 0), "kWh/persona")
```

Interpretación de coeficientes

```
1 # Coeficientes de la regresión lineal - Modelo de energía
2
3 # linreg_energy.coef_ contiene el coeficiente de cada predictor
4 coef_df_energy = pd.DataFrame({
5     "Variable": features_energy_final,
6     "Coeficiente": linreg_energy.coef_
7 })
8
9 print(coef_df_energy)
10 print("Intercept:", linreg_energy.intercept_)
```

Análisis de residuos

```
1 # Análisis de residuos - Modelo lineal de energía
2
3 # Calculamos los residuos
4 residuals_energy = y_test_energy - y_pred_energy
5
6 plt.figure(figsize=(8,6))
7 sns.scatterplot(x=y_pred_energy, y=residuals_energy, alpha=0.4)
8
9 # Si el modelo es adecuado los puntos deben estar dispersos aleatoriamente
10 plt.axhline(0, color='red', linestyle='--')
11 plt.xlabel("Consumo predicho (kWh/persona)")
12 plt.ylabel("Residuos")
```

```
13 plt.title("Residuos vs valores predichos - Modelo de energía")
14 plt.show()
```

Diagnóstico formal de residuos

```
1 # Diagnóstico formal de residuos - Modelo de energía per cápita
2
3 # Breusch-Pagan
4 lm_e, p_bp_e, _, _ = het_breuschpagan(
5     residuals_energy,
6     sm.add_constant(X_test_energy_scaled))
7
8 print("Test de Breusch-Pagan (heterocedasticidad)")
9 print(f"Estadístico LM: {lm_e:.3f}")
10 print(f"p-valor:      {p_bp_e:.4f}")
11 print()
12
13 # Durbin-Watson
14 dw_energy = durbin_watson(residuals_energy)
15
16 print("Test de Durbin-Watson (autocorrelación)")
17 print(f"Estadístico DW: {dw_energy:.3f} (valor ideal = 2)")
```

A.10.3. Ridge Regression

```
1 # Ridge Regression - Modelo de energía per cápita
2
3 grid_ridge_energy = GridSearchCV(
4     Ridge(),
5     {"alpha": [0.01, 0.1, 1, 10, 100, 1000]},
6     cv=5,
7     scoring="r2"
8 )
9
10 grid_ridge_energy.fit(X_train_energy_scaled, y_train_energy)
11 best_ridge_energy = grid_ridge_energy.best_estimator_
12
13 y_pred_ridge_energy = best_ridge_energy.predict(X_test_energy_scaled)
14
15 r2_ridge_energy = r2_score(y_test_energy, y_pred_ridge_energy)
16 mae_ridge_energy = mean_absolute_error(y_test_energy, y_pred_ridge_energy)
17 rmse_ridge_energy = np.sqrt(mean_squared_error(y_test_energy, y_pred_ridge_energy))
18
19 print("Mejor  $\alpha$ :", grid_ridge_energy.best_params_)
```

```
20 print("R2: ", round(r2_ridge_energy, 4))
21 print("MAE: ", round(mae_ridge_energy, 0), "kWh/persona")
22 print("RMSE:", round(rmse_ridge_energy, 0), "kWh/persona")
```

A.10.4. Random Forest

```
1  # Random Forest - Modelo de energía per cápita
2
3  param_grid_rf_energy = {
4      "max_depth": [5, 10, 15, 20, None]
5  }
6
7  rf_energy_base = RandomForestRegressor(
8      n_estimators=300,
9      random_state=42,
10     n_jobs=-1
11 )
12
13 grid_rf_energy = GridSearchCV(
14     rf_energy_base,
15     param_grid_rf_energy,
16     cv=5,
17     scoring="r2"
18 )
19
20 grid_rf_energy.fit(X_train_energy_scaled, y_train_energy)
21 rf_energy = grid_rf_energy.best_estimator_
22
23 y_pred_rf_energy = rf_energy.predict(X_test_energy_scaled)
24
25 r2_rf_energy = r2_score(y_test_energy, y_pred_rf_energy)
26 mae_rf_energy = mean_absolute_error(y_test_energy, y_pred_rf_energy)
27 rmse_rf_energy = np.sqrt(mean_squared_error(y_test_energy, y_pred_rf_energy))
28
29 print("Mejor max_depth:", grid_rf_energy.best_params_)
30 print("R2: ", round(r2_rf_energy, 4))
31 print("MAE: ", round(mae_rf_energy, 0), "kWh/persona")
32 print("RMSE:", round(rmse_rf_energy, 0), "kWh/persona")
```

Importancia de variables

```
1  # Importancia de variables - Random Forest de energía
2
3  importances_energy = rf_energy.feature_importances_
```



```

4
5 importance_df_energy = pd.DataFrame({
6     "Feature": features_energy_final,
7     "Importance": importances_energy
8 }).sort_values(by="Importance", ascending=False)
9
10 print(importance_df_energy)

```

A.11. VALIDACIÓN EXTERNA

A.11.1. Análisis de compatibilidad entre datasets

```

1  # Comparación de variables clave entre Kaggle y OWID para el año 2019
2  # Cruzamos ambos datasets para comprobar la compatibilidad antes de aplicar los
3
4  owid = pd.read_csv("owid-energy-data.csv")
5
6  countries_check = [
7      'China', 'United States', 'India', 'Japan',
8      'Germany', 'France', 'Spain',
9      'United Kingdom', 'Brazil', 'Australia', 'Russia'
10 ]
11 k2019 = df[df['Year'] == 2019]
12 o2019 = owid[owid['year'] == 2019]
13
14 # Consumo energético per cápita
15 # Esta es la variable objetivo del Modelo B, por lo que su compatibilidad entre
16 # es especialmente relevante
17 print("ENERGY PER CAPITA (kWh/persona)")
18 print(f"{'País':<22} {'Kaggle':>10} {'OWID':>10} {'Dif.%':>7}")
19 print("-" * 54)
20 for c in countries_check:
21     k = k2019[k2019['Entity'] == c]
22     o = o2019[o2019['country'] == c]
23     if k.empty or o.empty: continue
24     kv = k['Primary energy consumption per capita (kWh/person)'].values[0]
25     ov = o['energy_per_capita'].values[0]
26     print(f"{'c':<22} {'kv':>10,.0f} {'ov':>10,.0f} {'abs(kv-ov)/ov*100:>6.1f}%")
27
28 # Generación eléctrica fósil
29 # Variable predictor clave en ambos modelos
30 print()
31 print("GENERACIÓN ELÉCTRICA FÓSIL (TWh)")
32 print(f"{'País':<22} {'Kaggle':>10} {'OWID':>10} {'Dif.%':>7}")

```

```

33 print("-" * 54)
34 for c in countries_check:
35     k = k2019[k2019['Entity'] == c]
36     o = o2019[o2019['country'] == c]
37     if k.empty or o.empty: continue
38     kv = k['Electricity from fossil fuels (TWh)'].values[0]
39     ov = o['fossil_electricity'].values[0]
40     print(f"{c:<22} {kv:>10,.1f} {ov:>10,.1f} {abs(kv-ov)/ov*100:>6.1f}%")
41
42 # GDP per cápita
43 # Principal predictor del Modelo B (57% de importancia en RF)
44 print()
45 print("GDP PER CÁPITA (USD)")
46 print(f"{ 'País':<22} { 'Kaggle':>10} { 'OWID':>10} { 'Dif.%':>7}")
47 print("-" * 54)
48 for c in countries_check:
49     k = k2019[k2019['Entity'] == c]
50     o = o2019[o2019['country'] == c]
51     if k.empty or o.empty: continue
52     kv = k['gdp_per_capita'].values[0]
53     ov = o['gdp'].values[0] / o['population'].values[0]
54     print(f"{c:<22} {kv:>10,.0f} {ov:>10,.0f} {abs(kv-ov)/ov*100:>6.1f}%")
55
56 # Intensidad energética
57 # Segunda variable más importante del Modelo B (19% de importancia en RF)
58 # El denominador (PIB) se mide distinto en cada fuente, por lo que se muestra
59 # el factor de escala en lugar de la diferencia porcentual
60 print()
61 print("ENERGY INTENSITY (MJ/$GDP)")
62 print(f"{ 'País':<22} { 'Kaggle':>10} { 'OWID':>10} { 'Factor':>8}")
63 print("-" * 54)
64 for c in countries_check:
65     k = k2019[k2019['Entity'] == c]
66     o = o2019[o2019['country'] == c]
67     if k.empty or o.empty: continue
68     kv = k['Energy intensity level of primary energy (MJ/$2017 PPP GDP)'].values[0]
69     ov = o['energy_per_gdp'].values[0]
70     print(f"{c:<22} {kv:>10.2f} {ov:>10.2f} {kv/ov:>8.1f}x")

```